

Enseñándole a BirdNET a escuchar en criollo

Parte I

Diagnóstico

1. Introducción y motivación

BirdNET es un modelo de inteligencia artificial que reconoce especies de aves a partir de grabaciones de audio, entrenado con una enorme cantidad de ejemplos etiquetados. El problema es que esos ejemplos no están distribuidos de manera pareja entre regiones, pues la gran mayoría proviene de Norteamérica y Europa. De este modo, es esperable que el modelo reconozca mucho mejor a las aves de esas zonas que a las de Argentina, simplemente por haber visto muchos menos ejemplos de estas últimas. Como el LSD-Tector depende de que BirdNET identifique correctamente la avifauna local, este sesgo regional puede traducirse en errores sistemáticos de detección. Antes de intentar corregirlo, este diagnóstico busca responder dos preguntas concretas: cuánto se equivoca el modelo con las especies de la región y con qué otras las confunde, y en qué etapa interna del modelo se origina ese error, ya que la estrategia de reentrenamiento necesaria depende directamente de dónde esté el problema.

2. Selección de especies objetivo

2.1. Metodología

Para definir qué especies debía cubrir el reentrenamiento, se necesitaba primero saber cuáles son las aves realmente comunes en la zona del campo de prueba, y no simplemente una lista arbitraria. La fuente elegida fue eBird, una plataforma colaborativa donde observadores de todo el mundo registran sus avistamientos, y que ofrece una herramienta llamada *Bar Charts* (“Aves por semana” en su versión en español): permite descargar, para una región determinada, la frecuencia con la que cada especie fue reportada en las listas de observación de los usuarios, desglosada semana a semana a lo largo del año. Se utilizó esta herramienta para la región de Buenos Aires (código de región AR-B), tomando el rango histórico completo disponible, y se calculó para cada especie un valor único de frecuencia promedio anual, resultado de promediar sus 48 valores semanales. La frecuencia de una especie, tal como la calcula eBird, es la proporción de listas de observación completas en las que esa especie fue reportada: si de cada 100 salidas de observación registradas en la región una especie aparece en 70 de ellas, su frecuencia es 0.70.

El archivo descargado incluía, además de especies genuinas, una cantidad considerable de entradas que no corresponden a una especie identificada con certeza (identificaciones a nivel de género, ambiguas entre dos especies, o híbridos), las cuales se eliminaron de forma automática

antes de continuar. Sobre la lista ya limpia, se aplicó un corte por umbral de frecuencia para quedarse con las 200 especies más comunes de la región, y finalmente se descartaron 7 especies adicionales por no contar con suficientes grabaciones de referencia disponibles en Xeno-canto para poder evaluarlas más adelante. El resultado es la lista final de 193 especies objetivo que se usa a lo largo de todo este informe.

Tabla 1: Ranking completo de especies objetivo, ordenado por frecuencia de observación promedio anual según [eBird \(región AR-B\)](#).

Rank	Nombre común	Nombre científico	Código eBird	En BirdNET	Frecuencia
1	Rufous Hornero	<i>Furnarius rufus</i>	rufhor2	sí	0.698
2	Eared Dove	<i>Zenaida auriculata</i>	eardov1	sí	0.665
3	Picazuro Pigeon	<i>Patagioenas picazuro</i>	picpig2	sí	0.654
4	Great Kiskadee	<i>Pitangus sulphuratus</i>	grekis	sí	0.617
5	Monk Parakeet	<i>Myiopsitta monachus</i>	monpar	sí	0.602
6	Chimango Caracara	<i>Milvago chimango</i>	chicar1	sí	0.535
7	Rufous-collared Sparrow	<i>Zonotrichia capensis</i>	rucspa1	sí	0.498
8	Southern Lapwing	<i>Vanellus chilensis</i>	soulap1	sí	0.491
9	Rufous-bellied Thrush	<i>Turdus rufiventris</i>	rubthr1	sí	0.487
10	Chalk-browed Mockingbird	<i>Mimus saturninus</i>	chbmoc1	sí	0.453
11	Southern House Wren	<i>Troglodytes aedon</i>	houwre	sí	0.409
12	Rock Pigeon	<i>Columba livia</i>	rocpig	sí	0.407
13	House Sparrow	<i>Passer domesticus</i>	houspa	sí	0.394
14	Crested Caracara	<i>Caracara plancus</i>	y00678	sí	0.366
15	Grayish Baywing	<i>Agelaioides badius</i>	bawcow4	sí	0.290
16	European Starling	<i>Sturnus vulgaris</i>	eursta	sí	0.282
17	Shiny Cowbird	<i>Molothrus bonariensis</i>	shicow	sí	0.237
18	Saffron Finch	<i>Sicalis flaveola</i>	saffin	sí	0.224
19	Hooded Siskin	<i>Spinus magellanicus</i>	hoosis1	sí	0.217
20	Green-barred Woodpecker	<i>Colaptes melanochloros</i>	grbwoo3	sí	0.210
21	Spot-winged Pigeon	<i>Patagioenas maculosa</i>	spwpig3	sí	0.200
22	Brown-hooded Gull	<i>Chroicocephalus maculipennis</i>	brhgul2	sí	0.199
23	Neotropic Cormorant	<i>Nannopterum brasilianum</i>	neocor	sí	0.191
24	Picui Ground Dove	<i>Columbina picui</i>	pigdov1	sí	0.168
25	Roadside Hawk	<i>Rupornis magnirostris</i>	roahaw	sí	0.167
26	Yellow-billed Teal	<i>Anas flavirostris</i>	yebtea1	sí	0.164
27	Guira Cuckoo	<i>Guira guira</i>	guicuc1	sí	0.152
28	Barn Swallow	<i>Hirundo rustica</i>	barswa	sí	0.150
29	Glittering-bellied Emerald	<i>Chlorostilbon lucidus</i>	glbeme1	sí	0.147
30	Cattle Tyrant	<i>Machetornis rixosa</i>	cattytr	sí	0.147
31	Harris's Hawk	<i>Parabuteo unicinctus</i>	hrshaw	sí	0.144
32	Creamy-bellied Thrush	<i>Turdus amaurochalinus</i>	crbthr1	sí	0.142
33	Tropical Kingbird	<i>Tyrannus melancholicus</i>	trokin	sí	0.139
34	Great Egret	<i>Ardea alba</i>	greegr	sí	0.137
35	Snowy Egret	<i>Egretta thula</i>	snoegr	sí	0.137
36	Gray-breasted Martin	<i>Progne chalybea</i>	gybmar	sí	0.135
37	Brown-chested Martin	<i>Progne tapera</i>	brcmar1	sí	0.129
38	Masked Gnatcatcher	<i>Poliophtila dumicola</i>	masgna1	sí	0.128
39	Gilded Hummingbird	<i>Hylocharis chrysura</i>	gilhum1	sí	0.127
40	Grassland Yellow-Finch	<i>Sicalis luteola</i>	gryfin1	sí	0.126

continúa en la página siguiente

Tabla 1 – continuación

Rank	Nombre común	Nombre científico	Código eBird	En BirdNET	Frecuencia
41	White-crested Tyrannulet	<i>Serpophaga subcristata</i>	y01036	sí	0.123
42	Great Pampa-Finch	<i>Embernagra platensis</i>	grpfin1	sí	0.122
43	Brown-and-yellow Marshbird	<i>Pseudoleistes virescens</i>	baymar1	sí	0.118
44	Fork-tailed Flycatcher	<i>Tyrannus savana</i>	fotfly	sí	0.117
45	Black-necked Stilt	<i>Himantopus mexicanus</i>	bknsti	sí	0.117
46	Cocoi Heron	<i>Ardea cocoi</i>	cocher1	sí	0.117
47	Kelp Gull	<i>Larus dominicanus</i>	kelgul	sí	0.112
48	Yellow-billed Pintail	<i>Anas georgica</i>	yebpin1	sí	0.110
49	White-rumped Swallow	<i>Tachycineta leucorrhoa</i>	whrswa1	sí	0.108
50	Narrow-billed Woodcreeper	<i>Lepidocolaptes angustirostris</i>	nabwoo1	sí	0.107
51	Spectacled Tyrant	<i>Hymenops perspicillatus</i>	spetyr1	sí	0.106
52	White-faced Ibis	<i>Plegadis chihi</i>	whfibi	sí	0.105
53	American Kestrel	<i>Falco sparverius</i>	amekes	sí	0.101
54	Campo Flicker	<i>Colaptes campestris</i>	camfli1	sí	0.100
55	Burrowing Owl	<i>Athene cunicularia</i>	burow1	sí	0.099
56	Whistling Heron	<i>Syrigma sibilatrix</i>	whiher1	sí	0.096
57	White-tipped Dove	<i>Leptotila verreauxi</i>	whtdov	sí	0.093
58	Yellow-winged Blackbird	<i>Agelasticus thilius</i>	yewbla2	sí	0.092
59	Wren-like Rushbird	<i>Phleocryptes melanops</i>	wrlrus1	sí	0.092
60	Freckle-breasted Thornbird	<i>Phacellodomus striaticollis</i>	frbtho1	sí	0.089
61	Silver Teal	<i>Spatula versicolor</i>	siltea1	no	0.085
62	Tropical Parula	<i>Setophaga pitiayumi</i>	tropar	sí	0.085
63	Southern Screamer	<i>Chauna torquata</i>	souscr1	sí	0.082
64	Common Gallinule	<i>Gallinula chloropus</i>	commoo3	sí	0.081
65	Black-and-rufous Warbling Finch	<i>Poospiza nigrorufa</i>	barwaf1	sí	0.080
66	White-winged Coot	<i>Fulica leucoptera</i>	whwcoo1	no	0.078
67	Great Grebe	<i>Podiceps major</i>	gregre1	sí	0.078
68	White-tufted Grebe	<i>Rollandia rolland</i>	whtgre3	no	0.078
69	Sayaca Tanager	<i>Thraupis sayaca</i>	saytan1	sí	0.077
70	Red-gartered Coot	<i>Fulica armillata</i>	regcoo1	sí	0.075
71	Bare-faced Ibis	<i>Phimosus infuscatus</i>	bafibi1	sí	0.073
72	Yellow-chevroned Parakeet	<i>Brotogeris chiriri</i>	yecpar	sí	0.072
73	Spotted Nothura	<i>Nothura maculosa</i>	sponot1	sí	0.069
74	Screaming Cowbird	<i>Molothrus rufoaxillaris</i>	scrcow1	sí	0.069
75	Plumbeous Rail	<i>Pardirallus sanguinolentus</i>	plurai1	sí	0.068
76	Coscoroba Swan	<i>Coscoroba coscoroba</i>	cosswa1	sí	0.066
77	White-throated Hummingbird	<i>Leucochloris albicollis</i>	whthum2	sí	0.066
78	Red-fronted Coot	<i>Fulica rufifrons</i>	refcoo1	sí	0.065
79	Double-collared Seedeater	<i>Sporophila caerulescens</i>	docsee1	sí	0.062
80	Limpkin	<i>Aramus guarauna</i>	limpki	sí	0.062
81	Golden-crowned Warbler	<i>Basileuterus culicivorus</i>	gcrwar	sí	0.062
82	Snowy-crowned Tern	<i>Sterna trudeaui</i>	truter	sí	0.061
83	Variable Oriole	<i>Icterus pyrrhopterus</i>	epaori4	sí	0.061
84	Checkered Woodpecker	<i>Veniliornis mixtus</i>	chewoo3	sí	0.060

continúa en la página siguiente

Tabla 1 – continuación

Rank	Nombre común	Nombre científico	Código eBird	En BirdNET	Frecuencia
85	Red-crested Cardinal	<i>Paroaria coronata</i>	reccar	sí	0.058
86	Vermilion Flycatcher	<i>Pyrocephalus rubinus</i>	verfly	sí	0.058
87	Long-winged Harrier	<i>Circus buffoni</i>	lowhar1	sí	0.057
88	Lesser Yellowlegs	<i>Tringa flavipes</i>	lesyel	sí	0.057
89	White-faced Whistling-Duck	<i>Dendrocygna viduata</i>	wfwduc1	sí	0.055
90	Brazilian Teal	<i>Amazonetta brasiliensis</i>	bratea1	sí	0.054
91	Rufous-browed Peppershrike	<i>Cyclarhis gujanensis</i>	rubpep1	sí	0.050
92	Blue-and-white Swallow	<i>Pygochelidon cyanoleuca</i>	bawswa1	sí	0.049
93	Firewood-gatherer	<i>Anumbius annumbi</i>	firgat1	sí	0.048
94	Gray-cowled Wood-Rail	<i>Aramides cajaneus</i>	gycwor1	sí	0.046
95	American Oystercatcher	<i>Haematopus palliatus</i>	ameoys	sí	0.046
96	Small-billed Elaenia	<i>Elaenia parvirostris</i>	smbela1	sí	0.046
97	Ringed Teal	<i>Callonetta leucophrys</i>	rintea1	no	0.045
98	Black-necked Swan	<i>Cygnus melancoryphus</i>	blnswa2	sí	0.045
99	Gray-hooded Gull	<i>Chroicocephalus cirrocephalus</i>	grhgul	sí	0.044
100	Black-crowned Night Heron	<i>Nycticorax nycticorax</i>	bcnher	sí	0.044
101	Bran-colored Flycatcher	<i>Myiophobus fasciatus</i>	brcfly1	sí	0.044
102	Giant Wood-Rail	<i>Aramides ypecaha</i>	giwrail	sí	0.044
103	Sooty Tyrannulet	<i>Serpophaga nigricans</i>	sootyr1	sí	0.043
104	Long-tailed Meadowlark	<i>Leistes loyca</i>	lotmea1	sí	0.042
105	Wattled Jacana	<i>Jacana jacana</i>	watjac1	sí	0.042
106	Spix's Spinetail	<i>Synallaxis spixi</i>	spispi1	sí	0.042
107	Roseate Spoonbill	<i>Platalea ajaja</i>	rosspo1	sí	0.041
108	White-eyed Parakeet	<i>Psittacara leucophthalmus</i>	whepar2	sí	0.041
109	Chilean Flamingo	<i>Phoenicopterus chilensis</i>	chifla1	sí	0.041
110	Greater Yellowlegs	<i>Tringa melanoleuca</i>	greyel	sí	0.040
111	Sooty-fronted Spinetail	<i>Synallaxis frontalis</i>	sofspi1	sí	0.039
112	Chiloe Wigeon	<i>Mareca sibilatrix</i>	chiwig1	sí	0.038
113	Rosy-billed Pochard	<i>Netta peposaca</i>	robpoc1	no	0.038
114	Snail Kite	<i>Rostrhamus sociabilis</i>	snakit	sí	0.038
115	Southern Yellowthroat	<i>Geothlypis velata</i>	masyel5	no	0.036
116	White-cheeked Pintail	<i>Anas bahamensis</i>	whcpin	no	0.035
117	Buff-winged Cinclodes	<i>Cinclodes fuscus</i>	buwcin1	sí	0.035
118	White-browed Meadowlark	<i>Leistes superciliaris</i>	whbblla2	sí	0.035
119	Red-winged Tinamou	<i>Rhynchotus rufescens</i>	rewtin1	sí	0.035
120	Burrowing Parakeet	<i>Cyanoliseus patagonus</i>	burpar	sí	0.034
121	Streaked Flycatcher	<i>Myiodynastes maculatus</i>	strfly1	sí	0.033
122	White-tipped Plantcutter	<i>Phytotoma rutila</i>	whtpla1	sí	0.033
123	Rufous-sided Crake	<i>Laterallus melanophaius</i>	ruscra1	sí	0.033
124	White-tailed Kite	<i>Elanus leucurus</i>	whtkit	sí	0.033
125	Many-colored Rush Tyrant	<i>Tachuris rubrigastra</i>	mcrtyr1	sí	0.032
126	Pied-billed Grebe	<i>Podilymbus podiceps</i>	pibgre	sí	0.031
127	Ringed Kingfisher	<i>Megaceryle torquata</i>	rinkin1	sí	0.031
128	Solitary Black Cacique	<i>Cacicus solitarius</i>	sobcac1	sí	0.030

continúa en la página siguiente

Tabla 1 – continuación

Rank	Nombre común	Nombre científico	Código eBird	En BirdNET	Frecuencia
129	White-rumped Sandpiper	<i>Calidris fuscicollis</i>	whrsan	sí	0.030
130	Apomado Falcon	<i>Falco femoralis</i>	aplfal	sí	0.029
131	White-banded Mockingbird	<i>Mimus triurus</i>	whbmoc1	sí	0.028
132	Rufescent Tiger-Heron	<i>Tigrisoma lineatum</i>	ruther1	sí	0.028
133	Nanday Parakeet	<i>Aratinga nenday</i>	bkhpar	sí	0.027
134	White-winged Becard	<i>Pachyramphus polychopterus</i>	whwbec1	sí	0.027
135	Correndera Pipit	<i>Anthus correndera</i>	corpip1	sí	0.027
136	Blue-and-yellow Tanager	<i>Rauenia bonariensis</i>	baytan3	sí	0.027
137	Hudsonian Godwit	<i>Limosa haemastica</i>	hudgod	sí	0.026
138	Warbling Doradito	<i>Pseudocolopteryx flaviventris</i>	wardor1	sí	0.026
139	Austral Negrito	<i>Lessonia rufa</i>	ausneg1	no	0.025
140	Spot-flanked Gallinule	<i>Porphyriops melanops</i>	spfgal1	sí	0.025
141	Two-banded Plover	<i>Charadrius falklandicus</i>	twbplo1	sí	0.025
142	Western Cattle-Egret	<i>Bubulcus ibis</i>	categr1	sí	0.025
143	Black Skimmer	<i>Rynchops niger</i>	blkski	sí	0.024
144	Green Kingfisher	<i>Chloroceryle americana</i>	grnkin	sí	0.024
145	Black-capped Warbling Finch	<i>Microspingus melanoleucus</i>	bcwfin2	sí	0.023
146	Chotoy Spinetail	<i>Schoeniophylax phryganophilus</i>	chospi2	sí	0.023
147	Grassland Sparrow	<i>Ammodramus humeralis</i>	graspal	sí	0.023
148	Rufous-capped Antshrike	<i>Thamnophilus ruficapillus</i>	rucant1	sí	0.022
149	Chivi Vireo	<i>Vireo chivi</i>	chivir1	sí	0.022
150	Hepatic Tanager	<i>Piranga flava</i>	heptan	sí	0.021
151	Southern Martin	<i>Progne elegans</i>	soumar	sí	0.021
152	Cinnamon Teal	<i>Spatula cyanoptera</i>	cintea	sí	0.021
153	Striated Heron	<i>Butorides striata</i>	strher	sí	0.021
154	Yellow-browed Tyrant	<i>Satrapa icterophrys</i>	yebtyr2	no	0.021
155	Curve-billed Reedhaunter	<i>Limnornis curvirostris</i>	cubree1	sí	0.021
156	Greater Rhea	<i>Rhea americana</i>	grerhe1	sí	0.020
157	Sulphur-bearded Reedhaunter	<i>Limnornis sulphuriferus</i>	sutspi1	sí	0.020
158	Bluish-gray Saltator	<i>Saltator coerulescens</i>	grasal3	?	0.019
159	Scarlet-headed Blackbird	<i>Amblyramphus holosericeus</i>	schbla1	sí	0.019
160	Crested Myna	<i>Acridotheres cristatellus</i>	cremyn	sí	0.019
161	Long-tailed Reed Finch	<i>Donacospiza albifrons</i>	ltrfin1	sí	0.018
162	South American Tern	<i>Sterna hirundinacea</i>	soater1	sí	0.018
163	American Golden-Plover	<i>Pluvialis dominica</i>	amgplo	sí	0.017
164	Grass Wren	<i>Cistothorus platensis</i>	sedwre	sí	0.017
165	Royal Tern	<i>Thalasseus maximus</i>	royter1	sí	0.017
166	Chilean Swallow	<i>Tachycineta leucopyga</i>	chiswa1	sí	0.016
167	White Monjita	<i>Xolmis irupero</i>	whimon1	sí	0.016
168	Chestnut-capped Blackbird	<i>Chrysomus ruficapillus</i>	chcbla2	sí	0.016
169	Tufted Tit-Spinetail	<i>Leptasthenura platensis</i>	tutspi1	sí	0.016
170	Mottle-cheeked Tyrannulet	<i>Phylloscartes ventralis</i>	moctyr2	sí	0.015

continúa en la página siguiente

Tabla 1 – continuación

Rank	Nombre común	Nombre científico	Código eBird	En BirdNET	Frecuencia
171	Fulvous Whistling-Duck	<i>Dendrocygna bicolor</i>	fuwduc	sí	0.015
172	Yellow-billed Cardinal	<i>Paroaria capitata</i>	yebcar	sí	0.014
173	Diademed Tanager	<i>Stephanophorus diadematus</i>	diatan1	sí	0.013
174	Straneck's Tyrannulet	<i>Serpophaga griseicapilla</i>	gyctyr2	sí	0.013
175	Dusky-legged Guan	<i>Penelope obscura</i>	dulgua1	sí	0.013
176	Black-headed Duck	<i>Heteronetta atricapilla</i>	blhduc1	no	0.012
177	Pectoral Sandpiper	<i>Calidris melanotos</i>	pecsan	sí	0.012
178	Yellow-chinned Spinetail	<i>Certhiaxis cinnamomeus</i>	yecspi2	sí	0.011
179	Common Tern	<i>Sterna hirundo</i>	comter	sí	0.011
180	Bay-capped Wren-Spinetail	<i>Spartonoica maluroides</i>	bcwspi1	sí	0.011
181	Dark-billed Cuckoo	<i>Coccyzus melacoryphus</i>	dabcuc1	sí	0.011
182	European Greenfinch	<i>Chloris chloris</i>	eurgre1	sí	0.011
183	Graylag Goose	<i>Anser anser</i>	gragoo	sí	0.010
184	Green-winged Saltator	<i>Saltator similis</i>	grwsal1	sí	0.010
185	Wood Stork	<i>Mycteria americana</i>	woosto	sí	0.010
186	Tropical Screech-Owl	<i>Megascops choliba</i>	trsowl	sí	0.010
187	American Barn Owl	<i>Tyto alba</i>	webowl1	sí	0.010
188	Gray-throated Warbling Finch	<i>Microspingus cabanisi</i>	gytwaf1	sí	0.010
189	European Goldfinch	<i>Carduelis carduelis</i>	eurgol	sí	0.010
190	White-barred Piculet	<i>Picumnus cirratus</i>	whbpic1	sí	0.010
191	Black-browed Albatross	<i>Thalassarche melanophris</i>	bkbalb	sí	0.010
192	Sanderling	<i>Calidris alba</i>	sander	sí	0.010
193	Variable Antshrike	<i>Thamnophilus caerulescens</i>	varant1	sí	0.009

3. Evaluación baseline del modelo actual

Antes de reentrenar nada, hace falta saber con precisión qué tan bien funciona el modelo tal como está hoy. Para eso se necesita una medida cuantitativa de desempeño, y la más simple e intuitiva es el *accuracy*: el porcentaje de veces que el modelo acierta la especie correcta. Si se le muestran 100 grabaciones y acierta en 64, su *accuracy* es del 64 %.

Aplicar esta idea a BirdNET requiere algunas precisiones. El modelo no analiza una grabación entera de una sola vez, sino que la corta en ventanas de 3 segundos, y para cada una de esas ventanas produce una predicción independiente, con un valor de confianza asociado a cada especie posible. Una grabación de 30 segundos, por ejemplo, se traduce en 10 predicciones distintas, no en una sola. Para poder hablar de un único acierto o error por grabación, se toma la ventana en la que el modelo asignó la mayor confianza a alguna especie, y esa es la predicción que se usa para representar a toda la grabación. A este criterio se lo llama *top-1*: de todas las especies que el modelo consideró posibles, se mira únicamente cuál quedó en el primer lugar, la de mayor confianza, y se ignoran las demás.

Esa predicción *top-1* se compara luego contra la especie real de la grabación. Esto es posible porque el conjunto de audios usado para esta evaluación no son grabaciones ambiguas, sino que provienen de Xeno-canto, una base de datos colaborativa de sonidos de aves donde cada grabación fue subida y etiquetada por la persona que la registró, indicando de antemano qué especie es. Es decir, se conoce la respuesta correcta antes de mostrarle el audio al modelo, lo cual permite verificar automáticamente, grabación por grabación, si acertó o no.

3.1. Metodología del set de validación

Se armó un conjunto de validación de hasta 10 grabaciones por cada una de las 193 especies objetivo, obtenidas mediante la API pública de Xeno-canto, una base de datos colaborativa de grabaciones de aves. Las consultas se filtraron por calidad A o B (las categorías más altas que los propios usuarios de la plataforma asignan al subir cada grabación), de manera que el conjunto de validación estuviera compuesto por audio limpio y bien identificado. El límite de 10 grabaciones por especie era un tope máximo, no una cantidad fija. Algunas especies contaban con menos de 10 grabaciones que cumplieran ese filtro de calidad en toda la base de Xeno-canto, y en esos casos se incluyeron todas las disponibles, resultando en conjuntos de 5 o 6 grabaciones para esas especies puntuales. En total se obtuvieron 1930 grabaciones. Se le pasó cada una al modelo BirdNET actual (versión V2.4, sin restringir el conjunto de especies posibles ni la ubicación geográfica, para observar su comportamiento más general) y se comparó la predicción top-1 contra la especie real de cada grabación, conocida de antemano por el propio origen de los datos. Una pequeña fracción de los archivos descargados no pudo ser procesada por el modelo debido a problemas de formato o corrupción del archivo de audio.

3.2. Resultados globales

El modelo BirdNET actual, evaluado sobre las 1881 grabaciones del conjunto de validación que pudieron procesarse correctamente, alcanzó un *accuracy* top-1 global del 63.6 %. Es decir, algo más de 6 de cada 10 grabaciones fueron clasificadas correctamente en su primera predicción. Este número por sí solo confirma que existe un margen de mejora considerable, pero no dice nada todavía sobre cómo se distribuye ese error entre las 193 especies, ya que podría tratarse de un desempeño parejo y mediocre en todas ellas, o de un grupo de especies muy bien reconocidas junto con otro grupo donde el modelo falla casi por completo. La tabla siguiente desglosa el resultado especie por especie.

Tabla 2: Accuracy top-1 por especie, ordenado de menor a mayor.

Especie	Clips totales	Aciertos	Accuracy (%)
<i>Anas bahamensis</i>	9	0	0.0
<i>Callonetta leucophrys</i>	10	0	0.0
<i>Fulica leucoptera</i>	8	0	0.0
<i>Geothlypis velata</i>	10	0	0.0
<i>Heteronetta atricapilla</i>	5	0	0.0
<i>Hymenops perspicillatus</i>	9	0	0.0
<i>Lessonia rufa</i>	6	0	0.0
<i>Netta peposaca</i>	6	0	0.0
<i>Podiceps major</i>	10	0	0.0
<i>Rollandia rolland</i>	4	0	0.0
<i>Satrapa icterophrys</i>	9	0	0.0
<i>Spatula versicolor</i>	6	0	0.0
<i>Veniliornis mixtus</i>	10	0	0.0
<i>Ardea cocoi</i>	10	1	10.0
<i>Cistothorus platensis</i>	10	1	10.0
<i>Phimosus infuscatus</i>	10	1	10.0
<i>Rhea americana</i>	10	1	10.0
<i>Spatula cyanoptera</i>	10	1	10.0
<i>Phoenicopterus chilensis</i>	9	1	11.1
<i>Rauenia bonariensis</i>	9	1	11.1
<i>Chlorostilbon lucidus</i>	10	2	20.0
<i>Circus buffoni</i>	10	2	20.0

continúa en la página siguiente

Tabla 2 – continuación

Especie	Clips totales	Aciertos	Accuracy (%)
<i>Colaptes melanochloros</i>	10	2	20.0
<i>Egretta thula</i>	10	2	20.0
<i>Icterus pyrrhopterus</i>	10	2	20.0
<i>Mimus saturninus</i>	10	2	20.0
<i>Sporophila caerulescens</i>	10	2	20.0
<i>Sterna hirundinacea</i>	10	2	20.0
<i>Tachycineta leucorrhoa</i>	9	2	22.2
<i>Chloroceryle americana</i>	10	3	30.0
<i>Cyclarhis gujanensis</i>	10	3	30.0
<i>Fulica armillata</i>	10	3	30.0
<i>Limosa haemastica</i>	10	3	30.0
<i>Mimus triurus</i>	10	3	30.0
<i>Molothrus rufoaxillaris</i>	10	3	30.0
<i>Picumnus cirratus</i>	10	3	30.0
<i>Spinus magellanicus</i>	10	3	30.0
<i>Piranga flava</i>	9	3	33.3
<i>Anas flavirostris</i>	10	4	40.0
<i>Butorides striata</i>	10	4	40.0
<i>Calidris fuscicollis</i>	10	4	40.0
<i>Calidris melanotos</i>	10	4	40.0
<i>Caracara plancus</i>	10	4	40.0
<i>Chroicocephalus maculipennis</i>	10	4	40.0
<i>Larus dominicanus</i>	10	4	40.0
<i>Lepidocolaptes angustirostris</i>	10	4	40.0
<i>Microspingus melanoleucus</i>	10	4	40.0
<i>Saltator coerulescens</i>	10	4	40.0
<i>Syrigma sibilatrix</i>	10	4	40.0
<i>Tringa flavipes</i>	10	4	40.0
<i>Tringa melanoleuca</i>	10	4	40.0
<i>Zenaida auriculata</i>	10	4	40.0
<i>Paroaria capitata</i>	9	4	44.4
<i>Agelasticus thilius</i>	10	5	50.0
<i>Amazonetta brasiliensis</i>	10	5	50.0
<i>Anas georgica</i>	8	4	50.0
<i>Anser anser</i>	10	5	50.0
<i>Cacicus solitarius</i>	10	5	50.0
<i>Charadrius falklandicus</i>	6	3	50.0
<i>Chroicocephalus cirrocephalus</i>	10	5	50.0
<i>Cinclodes fuscus</i>	10	5	50.0
<i>Fulica rufifrons</i>	10	5	50.0
<i>Patagioenas picazuro</i>	10	5	50.0
<i>Polioptila dumicola</i>	10	5	50.0
<i>Porphyriops melanops</i>	10	5	50.0
<i>Serpophaga subcristata</i>	10	5	50.0
<i>Sterna trudeaui</i>	10	5	50.0
<i>Thalassarche melanophris</i>	10	5	50.0
<i>Turdus rufiventris</i>	10	5	50.0
<i>Zonotrichia capensis</i>	10	5	50.0
<i>Pseudocolopteryx flaviventris</i>	9	5	55.6
<i>Xolmis irupero</i>	9	5	55.6
<i>Acridotheres cristatellus</i>	10	6	60.0
<i>Ardea alba</i>	10	6	60.0
<i>Colaptes campestris</i>	10	6	60.0
<i>Elanus leucurus</i>	10	6	60.0
<i>Falco femoralis</i>	10	6	60.0
<i>Himantopus mexicanus</i>	10	6	60.0
<i>Megascops choliba</i>	10	6	60.0

continúa en la página siguiente

Tabla 2 – continuación

Especie	Clips totales	Aciertos	Accuracy (%)
<i>Microspingus cabanisi</i>	10	6	60.0
<i>Milvago chimango</i>	10	6	60.0
<i>Mycteria americana</i>	10	6	60.0
<i>Parabuteo unicinctus</i>	10	6	60.0
<i>Phylloscartes ventralis</i>	10	6	60.0
<i>Progne chalybea</i>	10	6	60.0
<i>Progne elegans</i>	10	6	60.0
<i>Sicalis luteola</i>	10	6	60.0
<i>Tachycineta leucopyga</i>	10	6	60.0
<i>Tigrisoma lineatum</i>	10	6	60.0
<i>Vireo chivi</i>	10	6	60.0
<i>Pygochelidon cyanoleuca</i>	9	6	66.7
<i>Serpophaga nigricans</i>	9	6	66.7
<i>Aramides ypecaha</i>	10	7	70.0
<i>Basileuterus culicivorus</i>	10	7	70.0
<i>Bubulcus ibis</i>	10	7	70.0
<i>Chrysomus ruficapillus</i>	10	7	70.0
<i>Falco sparverius</i>	10	7	70.0
<i>Gallinula chloropus</i>	10	7	70.0
<i>Hylocharis chrysura</i>	10	7	70.0
<i>Jacana jacana</i>	10	7	70.0
<i>Leistes loyca</i>	10	7	70.0
<i>Leistes superciliaris</i>	10	7	70.0
<i>Paroaria coronata</i>	10	7	70.0
<i>Phytotoma rutila</i>	10	7	70.0
<i>Rhynchotus rufescens</i>	10	7	70.0
<i>Setophaga pitiauyumi</i>	10	7	70.0
<i>Sturnus vulgaris</i>	10	7	70.0
<i>Thraupis sayaca</i>	10	7	70.0
<i>Troglodytes aedon</i>	10	7	70.0
<i>Coccyzus melacoryphus</i>	9	7	77.8
<i>Ammodramus humeralis</i>	10	8	80.0
<i>Chauna torquata</i>	10	8	80.0
<i>Elaenia parvirostris</i>	10	8	80.0
<i>Furnarius rufus</i>	10	8	80.0
<i>Guira guira</i>	10	8	80.0
<i>Leptotila verreauxi</i>	10	8	80.0
<i>Limnortites sulphuriferus</i>	10	8	80.0
<i>Limnornis curvirostris</i>	10	8	80.0
<i>Molothrus bonariensis</i>	10	8	80.0
<i>Myiophobus fasciatus</i>	10	8	80.0
<i>Nannopterum brasilianum</i>	10	8	80.0
<i>Phleocryptes melanops</i>	10	8	80.0
<i>Pitangus sulphuratus</i>	10	8	80.0
<i>Progne tapera</i>	10	8	80.0
<i>Psittacara leucophthalmus</i>	10	8	80.0
<i>Rostrhamus sociabilis</i>	10	8	80.0
<i>Rupornis magnirostris</i>	10	8	80.0
<i>Serpophaga griseicapilla</i>	10	8	80.0
<i>Spartonoica maluioides</i>	10	8	80.0
<i>Stephanophorus diadematus</i>	10	8	80.0
<i>Thalasseus maximus</i>	10	8	80.0
<i>Thamnophilus caerulescens</i>	10	8	80.0
<i>Tyrannus melancholicus</i>	10	8	80.0
<i>Tyto alba</i>	10	8	80.0
<i>Vanellus chilensis</i>	10	8	80.0
<i>Columbina picui</i>	8	7	87.5

continúa en la página siguiente

Tabla 2 – continuación

Especie	Clips totales	Aciertos	Accuracy (%)
<i>Aratinga nenday</i>	9	8	88.9
<i>Dendrocygna bicolor</i>	9	8	88.9
<i>Agelaioides badius</i>	10	9	90.0
<i>Amblyramphus holosericeus</i>	10	9	90.0
<i>Anthus correndera</i>	10	9	90.0
<i>Athene cunicularia</i>	10	9	90.0
<i>Brotogeris chiriri</i>	10	9	90.0
<i>Calidris alba</i>	10	9	90.0
<i>Cygnus melancoryphus</i>	10	9	90.0
<i>Dendrocygna viduata</i>	10	9	90.0
<i>Donacospiza albifrons</i>	10	9	90.0
<i>Embernagra platensis</i>	10	9	90.0
<i>Haematopus palliatus</i>	10	9	90.0
<i>Hirundo rustica</i>	10	9	90.0
<i>Laterallus melanophaius</i>	10	9	90.0
<i>Leptasthenura platensis</i>	10	9	90.0
<i>Mareca sibilatrix</i>	10	9	90.0
<i>Myiodynastes maculatus</i>	10	9	90.0
<i>Pardirallus sanguinolentus</i>	10	9	90.0
<i>Passer domesticus</i>	10	9	90.0
<i>Phacellodomus striaticollis</i>	10	9	90.0
<i>Platalea ajaja</i>	10	9	90.0
<i>Plegadis chihi</i>	10	9	90.0
<i>Pluvialis dominica</i>	10	9	90.0
<i>Poospiza nigrorufa</i>	10	9	90.0
<i>Pyrocephalus rubinus</i>	10	9	90.0
<i>Saltator similis</i>	10	9	90.0
<i>Tachuris rubrigastra</i>	10	9	90.0
<i>Anumbius annumbi</i>	10	10	100.0
<i>Aramides cajaneus</i>	10	10	100.0
<i>Aramus guarauna</i>	10	10	100.0
<i>Carduelis carduelis</i>	10	10	100.0
<i>Certhiaxis cinnamomeus</i>	10	10	100.0
<i>Chloris chloris</i>	10	10	100.0
<i>Columba livia</i>	10	10	100.0
<i>Coscoroba coscoroba</i>	10	10	100.0
<i>Cyanoliseus patagonus</i>	10	10	100.0
<i>Leucochloris albicollis</i>	10	10	100.0
<i>Machetornis rixosa</i>	10	10	100.0
<i>Megasceryle torquata</i>	10	10	100.0
<i>Myiopsitta monachus</i>	10	10	100.0
<i>Nothura maculosa</i>	10	10	100.0
<i>Nycticorax nycticorax</i>	10	10	100.0
<i>Pachyramphus polychopterus</i>	10	10	100.0
<i>Patagioenas maculosa</i>	10	10	100.0
<i>Penelope obscura</i>	10	10	100.0
<i>Podilymbus podiceps</i>	10	10	100.0
<i>Pseudoleistes virescens</i>	10	10	100.0
<i>Rynchops niger</i>	10	10	100.0
<i>Schoeniophylax phryganophilus</i>	10	10	100.0
<i>Sicalis flaveola</i>	10	10	100.0
<i>Sterna hirundo</i>	10	10	100.0
<i>Synallaxis frontalis</i>	10	10	100.0
<i>Synallaxis spixi</i>	10	10	100.0
<i>Thamnophilus ruficapillus</i>	9	9	100.0
<i>Turdus amaurochalinus</i>	10	10	100.0
<i>Tyrannus savana</i>	10	10	100.0

Vale la pena detenerse en los casos más extremos de la tabla anterior: 13 especies obtuvieron 0% de accuracy, es decir, el modelo no acertó ni una sola de sus grabaciones de validación. Al revisar cuáles son, aparece una explicación clara para la mayoría de ellas: especies como *Netta peposaca*, *Fulica leucoptera*, *Rollandia rolland*, *Callonetta leucophrys*, *Heteronetta atricapilla* o *Spatula versicolor* directamente no forman parte del catálogo de especies que BirdNET es capaz de reconocer, con lo cual estaban destinadas a fallar. Un caso aparte dentro de este mismo grupo es *Veniliornis mixtus*, ya que no es que le falte al catálogo, sino que figura bajo un nombre científico distinto, *Dryobates mixtus*, que es la denominación taxonómica actual de la misma especie. Al consultarse por el nombre antiguo, el modelo nunca la reconoce, un desajuste de nomenclatura y no un error de discriminación acústica. El resto de las especies con 0% sí están incluidas en el catálogo de BirdNET y, a diferencia de las anteriores, representan casos genuinos de sesgo regional que el reentrenamiento debería poder corregir.

La tabla anterior permite revisar el desempeño de cualquier especie en particular, pero resulta poco práctica para captar el panorama general de las 193 en conjunto. El histograma siguiente resume esa misma información de forma agregada, agrupando a las especies según su rango de accuracy y mostrando cuántas caen en cada tramo.




Figura 1: Distribución de *accuracy* top-1 entre las 193 especies evaluadas.

Este histograma funciona además como indicador del efecto del reentrenamiento, ya que una vez completado, se repetirá exactamente el mismo procedimiento de evaluación sobre el mismo conjunto de validación, y se generará el histograma equivalente con idéntico binado. Comparar ambas distribuciones, antes y después, permitirá ver directamente si el reentrenamiento logró desplazar las especies hacia valores de accuracy más altos, o si simplemente redujo la dispersión sin mejorar el promedio general.

4. Identificación de patrones de confusión

El accuracy global y el desglose por especie de la sección anterior dicen *cuánto* falla el modelo, pero no dicen nada sobre *en qué se equivoca* cuando falla. Saber que una especie tuvo baja accuracy es útil, pero mucho más útil es saber con qué otra especie la está confundiendo el modelo, porque eso permite entender si los errores siguen algún patrón reconocible o si son simplemente ruido aleatorio. La herramienta estándar para responder esa pregunta es la ma-

triz de confusión: una tabla que cruza, para cada grabación evaluada, la especie real contra la especie que el modelo predijo, permitiendo ver de un vistazo no solo cuántos aciertos hubo, sino exactamente hacia dónde se fueron los errores.

4.1. Metodología

La matriz de confusión se construyó reutilizando el mismo conjunto de validación y las mismas predicciones top-1 obtenidas en la sección anterior: para cada una de las 1881 grabaciones procesadas, se registró el par (especie real, especie predicha). Estos pares se agruparon en una tabla de doble entrada, donde las filas representan la especie real y las columnas la especie que el modelo predijo; cada celda indica cuántas veces ocurrió esa combinación particular. Los aciertos quedan sobre la diagonal de la tabla (donde la especie real y la predicha coinciden), mientras que cualquier valor fuera de la diagonal representa un error, y la posición de ese valor indica exactamente con qué especie se confundió.

A partir de esta matriz completa se generó, además, un ranking resumido en el que para cada especie con al menos un error, se identificó cuál fue la especie con la que más frecuentemente se la confundió, y se calculó qué porcentaje de sus grabaciones de validación cayeron en esa confusión particular. Este ranking, ordenado de mayor a menor porcentaje, es el que permite priorizar qué pares de especies requieren mayor atención al momento de armar el conjunto de datos para el reentrenamiento.

4.2. Tabla completa del ranking de confusiones

Tabla 3: Ranking completo de pares de especies confundidas por el modelo, ordenado por porcentaje de confusión.

Especie real	Confundida con	Veces	Confusión (%)
<i>Geothlypis velata</i>	<i>Geothlypis aequinoctialis</i>	8	80.0
<i>Chroicocephalus maculipennis</i>	<i>Chroicocephalus ridibundus</i>	5	50.0
<i>Anas flavirostris</i>	<i>Anas crecca</i>	4	40.0
<i>Anas georgica</i>	<i>Anas acuta</i>	3	37.5
<i>Ardea cocoi</i>	<i>Ardea herodias</i>	3	30.0
<i>Callonetta leucophrys</i>	<i>Sturnus unicolor</i>	3	30.0
<i>Egretta thula</i>	<i>Egretta caerulea</i>	3	30.0
<i>Falco sparverius</i>	<i>Falco columbarius</i>	3	30.0
<i>Fulica leucoptera</i>	<i>Fulica atra</i>	3	37.5
<i>Hymenops perspicillatus</i>	<i>Sicalis luteola</i>	3	33.3
<i>Larus dominicanus</i>	<i>Larus argentatus</i>	3	30.0
<i>Mycteria americana</i>	<i>Ardea alba</i>	3	30.0
<i>Progne elegans</i>	<i>Progne chalybea</i>	3	30.0
<i>Spatula cyanoptera</i>	<i>Fulica americana</i>	3	30.0
<i>Sporophila caerulea</i>	<i>Sporophila nigricollis</i>	3	30.0
<i>Sterna hirundinacea</i>	<i>Thalasseus sandvicensis</i>	3	30.0
<i>Tringa melanoleuca</i>	<i>Tringa flavipes</i>	3	30.0
<i>Veniliornis mixtus</i>	<i>Dryobates mixtus</i>	3	30.0
<i>Butorides striata</i>	<i>Butorides virescens</i>	2	20.0
<i>Caracara plancus</i>	<i>Pica pica</i>	2	20.0
<i>Chloroceryle americana</i>	<i>Opisthocomus hoazin</i>	2	20.0
<i>Cinclodes fuscus</i>	<i>Asthenes pyrrholeuca</i>	2	20.0
<i>Circus buffoni</i>	<i>Rallus limicola</i>	2	20.0
<i>Cyclarhis gujanensis</i>	<i>Cyclarhis nigrirostris</i>	2	20.0

continúa en la página siguiente

Tabla 3 – continuación

Especie real	Confundida con	Veces	Confusión (%)
<i>Fulica armillata</i>	<i>Chroicocephalus maculipennis</i>	2	20.0
<i>Fulica rufifrons</i>	<i>Podiceps cristatus</i>	2	20.0
<i>Heteronetta atricapilla</i>	<i>Phleocryptes melanops</i>	2	40.0
<i>Himantopus mexicanus</i>	<i>Zenaida asiatica</i>	2	20.0
<i>Hylocharis chrysura</i>	<i>Urosphena squameiceps</i>	2	20.0
<i>Leistes loyca</i>	<i>Rhopospina fruticeti</i>	2	20.0
<i>Mimus saturninus</i>	<i>Mimus gilvus</i>	2	20.0
<i>Molothrus rufoaxillaris</i>	<i>Linaria flavirostris</i>	2	20.0
<i>Phimosus infuscatus</i>	<i>Amaurornis moluccana</i>	2	20.0
<i>Pitangus sulphuratus</i>	<i>Tolmomyias flaviventris</i>	2	20.0
<i>Podiceps major</i>	<i>Calidris alpina</i>	2	20.0
<i>Progne chalybea</i>	<i>Human vocal</i>	2	20.0
<i>Rauenia bonariensis</i>	<i>Hemithraupis guira</i>	2	22.2
<i>Rollandia rolland</i>	<i>Aythya collaris</i>	2	50.0
<i>Rupornis magnirostris</i>	<i>Amazona auropalliata</i>	2	20.0
<i>Spatula versicolor</i>	<i>Calidris melanotos</i>	2	33.3
<i>Sterna trudeaui</i>	<i>Phleocryptes melanops</i>	2	20.0
<i>Tachycineta leucopyga</i>	<i>Cichlocolaptes leucophrus</i>	2	20.0
<i>Tachycineta leucorrhoa</i>	<i>Stelgidopteryx serripennis</i>	2	22.2
<i>Thalassarche melanophris</i>	<i>Human vocal</i>	2	20.0
<i>Tigrisoma lineatum</i>	<i>Megascops watsonii</i>	2	20.0
<i>Acridotheres cristatellus</i>	<i>Acridotheres tristis</i>	1	10.0
<i>Agelaioides badius</i>	<i>Sitta europaea</i>	1	10.0
<i>Agelastus thilius</i>	<i>Anthus lutescens</i>	1	10.0
<i>Amazonetta brasiliensis</i>	<i>Apus melba</i>	1	10.0
<i>Amblyramphus holosericeus</i>	<i>Sporophila leucoptera</i>	1	10.0
<i>Ammodramus humeralis</i>	<i>Artemisiospiza belli</i>	1	10.0
<i>Anas bahamensis</i>	<i>Anthus pratensis</i>	1	11.1
<i>Anser anser</i>	<i>Fulmarus glacialis</i>	1	10.0
<i>Anthus correndera</i>	<i>Anthus hellmayri</i>	1	10.0
<i>Aramides ypecaha</i>	<i>Agelaioides badius</i>	1	10.0
<i>Aratinga nenday</i>	<i>Empidonax hammondi</i>	1	11.1
<i>Ardea alba</i>	<i>Ardea cinerea</i>	1	10.0
<i>Athene cunicularia</i>	<i>Sicalis flaveola</i>	1	10.0
<i>Basileuterus culicivorus</i>	<i>Crypturellus undulatus</i>	1	10.0
<i>Brotogeris chiriri</i>	<i>Brotogeris tirica</i>	1	10.0
<i>Bubulcus ibis</i>	<i>Gallinago imperialis</i>	1	10.0
<i>Cacicus solitarius</i>	<i>Icterus icterus</i>	1	10.0
<i>Calidris alba</i>	<i>Vireo vicinior</i>	1	10.0
<i>Calidris fuscicollis</i>	<i>Anthus pratensis</i>	1	10.0
<i>Calidris melanotos</i>	<i>Anas platyrhynchos</i>	1	10.0
<i>Charadrius falklandicus</i>	<i>Actitis macularius</i>	1	16.7
<i>Chauna torquata</i>	<i>Brotogeris jugularis</i>	1	10.0
<i>Chlorostilbon lucidus</i>	<i>Acrocephalus scirpaceus</i>	1	10.0
<i>Chroicocephalus cirrocephalus</i>	<i>Chroicocephalus novaehollandiae</i>	1	10.0
<i>Chrysomus ruficapillus</i>	<i>Guira guira</i>	1	10.0
<i>Cistothorus platensis</i>	<i>Cistothorus palustris</i>	1	10.0
<i>Coccyzus melacoryphus</i>	<i>Callipepla gambelii</i>	1	11.1
<i>Colaptes campestris</i>	<i>Attila bolivianus</i>	1	10.0
<i>Colaptes melanochloros</i>	<i>Agelaioides badius</i>	1	10.0
<i>Columbina picui</i>	<i>Patagioenas plumbea</i>	1	12.5
<i>Cygnus melancoryphus</i>	<i>Podiceps gallardoi</i>	1	10.0
<i>Dendrocygna bicolor</i>	<i>Scleroptila gutturalis</i>	1	11.1

continúa en la página siguiente

Tabla 3 – continuación

Especie real	Confundida con	Veces	Confusión (%)
<i>Dendrocygna viduata</i>	<i>Tringa ochropus</i>	1	10.0
<i>Donacospiza albifrons</i>	<i>Melospiza kieneri</i>	1	10.0
<i>Elaenia parvirostris</i>	<i>Cnemotriccus fuscatus</i>	1	10.0
<i>Elanus leucurus</i>	<i>Gnorimopsar chopi</i>	1	10.0
<i>Embernagra platensis</i>	<i>Emberiza pusilla</i>	1	10.0
<i>Falco femoralis</i>	<i>Athene noctua</i>	1	10.0
<i>Furnarius rufus</i>	<i>Pitangus sulphuratus</i>	1	10.0
<i>Gallinula chloropus</i>	<i>Acrocephalus stentoreus</i>	1	10.0
<i>Guira guira</i>	<i>Eupetomena macroura</i>	1	10.0
<i>Haematopus palliatus</i>	<i>Haematopus ostralegus</i>	1	10.0
<i>Hirundo rustica</i>	<i>Motacilla flava</i>	1	10.0
<i>Icterus pyrrhopterus</i>	<i>Acrocephalus australis</i>	1	10.0
<i>Jacana jacana</i>	<i>Butorides virescens</i>	1	10.0
<i>Laterallus melanophaius</i>	<i>Amazona amazonica</i>	1	10.0
<i>Leistes supercilialis</i>	<i>Leistes militaris</i>	1	10.0
<i>Lepidocolaptes angustirostris</i>	<i>Furnarius rufus</i>	1	10.0
<i>Leptasthenura platensis</i>	<i>Cranioleuca pyrrhophia</i>	1	10.0
<i>Leptotila verreauxi</i>	<i>Pyrrhura frontalis</i>	1	10.0
<i>Lessonia rufa</i>	<i>Artemisiospiza nevadensis</i>	1	16.7
<i>Limnortyx sulphuriferus</i>	<i>Leistes supercilialis</i>	1	10.0
<i>Limnortyx curvirostris</i>	<i>Limnortyx sulphuriferus</i>	1	10.0
<i>Limosa haemastica</i>	<i>Attagis gayi</i>	1	10.0
<i>Mareca sibilatrix</i>	<i>Gallinula galeata</i>	1	10.0
<i>Megascops choliba</i>	<i>Athene noctua</i>	1	10.0
<i>Microspingus cabanisi</i>	<i>Carduelis carduelis</i>	1	10.0
<i>Microspingus melanoleucus</i>	<i>Ploceus manyar</i>	1	10.0
<i>Milvago chimango</i>	<i>Buteo jamaicensis</i>	1	10.0
<i>Mimus triurus</i>	<i>Cinchoramphus timoriensis</i>	1	10.0
<i>Molothrus bonariensis</i>	<i>Dysithamnus occidentalis</i>	1	10.0
<i>Myiodynastes maculatus</i>	<i>Clibanornis dendrocolaptoides</i>	1	10.0
<i>Myiophobus fasciatus</i>	<i>Dryocopus lineatus</i>	1	10.0
<i>Nannopterum brasilianum</i>	<i>Euphonia chlorotica</i>	1	10.0
<i>Netta peposaca</i>	<i>Chiroxiphia caudata</i>	1	16.7
<i>Parabuteo unicinctus</i>	<i>Asio otus</i>	1	10.0
<i>Pardirallus sanguinolentus</i>	<i>Gallirallus philippensis</i>	1	10.0
<i>Paroaria capitata</i>	<i>Acrocephalus paludicola</i>	1	11.1
<i>Paroaria coronata</i>	<i>Agelaioides badius</i>	1	10.0
<i>Passer domesticus</i>	<i>Falco naumanni</i>	1	10.0
<i>Patagioenas picazuro</i>	<i>Apaloderma narina</i>	1	10.0
<i>Phacellodomus striaticollis</i>	<i>Phacellodomus sibilatrix</i>	1	10.0
<i>Phleocryptes melanops</i>	<i>Certhiaxis cinnamomeus</i>	1	10.0
<i>Phoenicopterus chilensis</i>	<i>Anser canagicus</i>	1	11.1
<i>Phylloscartes ventralis</i>	<i>Basileuterus culicivorus</i>	1	10.0
<i>Phytotoma rutila</i>	<i>Argya malcolmi</i>	1	10.0
<i>Picumnus cirratus</i>	<i>Dryobates villosus</i>	1	10.0
<i>Piranga flava</i>	<i>Cariama cristata</i>	1	11.1
<i>Platalea ajaja</i>	<i>Coragyps atratus</i>	1	10.0
<i>Plegadis chihi</i>	<i>Mycteria americana</i>	1	10.0
<i>Pluvialis dominica</i>	<i>Pluvialis fulva</i>	1	10.0

continúa en la página siguiente

Tabla 3 – continuación

Especie real	Confundida con	Veces	Confusión (%)
<i>Poliophtila dumicola</i>	<i>Actitis macularius</i>	1	10.0
<i>Poospiza nigrorufa</i>	<i>Vanellus senegallus</i>	1	10.0
<i>Porphyriops melanops</i>	<i>Asthenes coryi</i>	1	10.0
<i>Progne tapera</i>	<i>Curruca communis</i>	1	10.0
<i>Pseudocolaptes</i> <i>flaviventris</i>	<i>Chloroceryle amazona</i>	1	11.1
<i>Psittacara</i> <i>leucophthalmus</i>	<i>Brotoyeris chiriri</i>	1	10.0
<i>Pygochelidon cyanoleuca</i>	<i>Auriparus flaviceps</i>	1	11.1
<i>Pyrocephalus rubinus</i>	<i>Zonotrichia capensis</i>	1	10.0
<i>Rhea americana</i>	<i>Aramides ypecaha</i>	1	10.0
<i>Rhynchotus rufescens</i>	<i>Fulica atra</i>	1	10.0
<i>Rostrhamus sociabilis</i>	<i>Aramus guarauna</i>	1	10.0
<i>Saltator coerulescens</i>	<i>Furnarius rufus</i>	1	10.0
<i>Saltator similis</i>	<i>Ilicura militaris</i>	1	10.0
<i>Satrapa icterophrys</i>	<i>Andropadus importunus</i>	1	11.1
<i>Serpophaga griseicapilla</i>	<i>Apus pallidus</i>	1	10.0
<i>Serpophaga nigricans</i>	<i>Aeronautes montivagus</i>	1	11.1
<i>Serpophaga subcristata</i>	<i>Cranioleuca pyrrhophia</i>	1	10.0
<i>Setophaga pitiauyumi</i>	<i>Amazona mercenarius</i>	1	10.0
<i>Sicalis luteola</i>	<i>Emberiza cioides</i>	1	10.0
<i>Spartonoica maluroides</i>	<i>Anthus correndera</i>	1	10.0
<i>Spinus magellanicus</i>	<i>Camaroptera brachyura</i>	1	10.0
<i>Stephanophorus</i> <i>diadematus</i>	<i>Cyclarhis gujanensis</i>	1	10.0
<i>Sturnus vulgaris</i>	<i>Buteo buteo</i>	1	10.0
<i>Syrigma sibilatrix</i>	<i>Burhinus oedipnemus</i>	1	10.0
<i>Tachuris rubrigastra</i>	<i>Phleocryptes melanops</i>	1	10.0
<i>Thalasseus maximus</i>	<i>Arenaria interpres</i>	1	10.0
<i>Thamophilus</i> <i>caerulescens</i>	<i>Chiroxiphia caudata</i>	1	10.0
<i>Thraupis sayaca</i>	<i>Euphonia violacea</i>	1	10.0
<i>Tringa flavipes</i>	<i>Colaptes melanochloros</i>	1	10.0
<i>Troglodytes aedon</i>	<i>Anthus trivialis</i>	1	10.0
<i>Turdus rufiventris</i>	<i>Agelaioides badius</i>	1	10.0
<i>Tyrannus melancholicus</i>	<i>Campylorhynchus</i> <i>turdinus</i>	1	10.0
<i>Tyto alba</i>	<i>Procnias albus</i>	1	10.0
<i>Vanellus chilensis</i>	<i>Accipiter gentilis</i>	1	10.0
<i>Vireo chivi</i>	<i>Columbina squammata</i>	1	10.0
<i>Xolmis irupero</i>	<i>Grallaria quitensis</i>	1	11.1
<i>Zenaida auriculata</i>	<i>Dryobates pubescens</i>	1	10.0
<i>Zonotrichia capensis</i>	<i>Chlorornis riefferii</i>	1	10.0

Al observar el ranking completo, aparece un patrón claro. La gran mayoría de las confusiones más frecuentes ocurren entre especies del mismo género taxonómico. El caso más marcado es *Geothlypis velata*, confundida con *Geothlypis aequinoctialis* en el 80 % de sus grabaciones, pero el patrón se repite en varios otros pares del tope de la tabla: *Anas flavirostris* con *Anas crecca*, *Anas georgica* con *Anas acuta*, *Fulica leucoptera* con *Fulica atra*, *Egretta thula* con *Egretta caerulea*, entre otros. Esto tiene sentido desde un punto de vista biológico, ya que especies emparentadas suelen compartir estructuras acústicas similares en sus cantos, así que resulta razonable que el modelo tienda a confundir a una especie local con el pariente cercano mejor representado en su catálogo, antes que con una especie sin relación alguna.

Dentro de este mismo ranking vuelve a aparecer el caso de *Veniliornis mixtus*, confundida en un 30 % de sus grabaciones con *Dryobates mixtus*. Como ya se discutió en la sección anterior, no

se trata de una confusión acústica genuina sino de un desajuste de nomenclatura, pues ambos nombres corresponden a la misma especie bajo dos sinonimias taxonómicas distintas.

Sin embargo, no todas las confusiones del ranking siguen el patrón intra-género. Un ejemplo notable es *Callonetta leucophrys* (pato de collar, un ave acuática sudamericana), confundida en un 30 % de sus grabaciones con *Sturnus unicolor* (estornino negro, una especie de la península ibérica). Se trata de dos aves sin ninguna relación taxonómica ni ecológica cercana, lo cual sugiere un mecanismo distinto. Ante una especie local mal representada en el catálogo, el modelo puede terminar asignándola a cualquier especie extranjera bien representada que le resulte acústicamente más cercana, sin que medie ningún parecido biológico real entre ambas.

5. Análisis de la causa: ¿la red “sabe” distinguir estas especies?

Hasta acá se estableció cuánto falla el modelo y con qué patrón se equivoca, pero queda pendiente la profunda pregunta de porqué falla. Para responderla hace falta abrir un poco la caja negra de BirdNET y entender, a grandes rasgos, cómo procesa internamente un sonido. Una red neuronal como esta no funciona en un solo paso, sino que primero transforma cada grabación en una representación numérica interna, y recién después usa esa representación para decidir a qué especie pertenece. Esto importa porque el problema de sesgo regional podría originarse en cualquiera de esas dos etapas, y cada una requiere una solución distinta. Si la representación numérica interna ya distingue bien entre dos especies pero la decisión final igual se equivoca, alcanza con corregir esa decisión final, un ajuste relativamente simple. Si en cambio la representación misma no logra diferenciarlas, hace falta una intervención mucho más profunda sobre el modelo. Este análisis busca determinar, para los pares de especies más confundidos identificados en la sección anterior, en cuál de las dos etapas se origina realmente el problema.

5.1. Qué es un *embedding*

Esa representación numérica interna que genera la red se llama *embedding*. La idea es que cuando BirdNET recibe una grabación de 3 segundos, no la analiza tal cual como sonido, sino que primero la convierte en una lista de 1024 números. Esa lista se puede pensar como una especie de huella digital acústica del sonido, donde se comprime toda la información relevante del audio (el timbre, el ritmo, etc.) en un formato puramente numérico que la propia red puede seguir procesando. Es decir, dos grabaciones que suenen parecido para la red van a generar dos *embeddings* parecidos entre sí, es decir, dos vectores de $\mathbb{R}^{1024}$ separados por poca distancia euclídea. Recién después de calcular este *embedding*, la red usa esos 1024 números como entrada de una última etapa de decisión, mucho más simple, que es la que finalmente elige a qué especie asignar el sonido.

Lo importante de esta idea para el diagnóstico es que el *embedding* y la decisión final son dos cosas separables, y se pueden estudiar por separado. Es posible, en principio, que dos especies generen *embeddings* bien diferenciados (la red captura bien la diferencia entre ellas a nivel de esos 1024 números) pero que la etapa de decisión final igual las confunda, por ejemplo porque nunca vio suficientes ejemplos de una de las dos especies como para aprender a aprovechar esa diferencia ya presente en el *embedding*.

5.2. Qué es un UMAP y para qué se usa acá

El problema práctico es que 1024 números por grabación son imposibles de visualizar directamente. Para poder inspeccionar visualmente si los *embeddings* de dos especies están bien

diferenciados o mezclados entre sí, se necesita alguna forma de reducir esas 1024 dimensiones a algo que se pueda dibujar en 2 dimensiones. UMAP (*Uniform Manifold Approximation and Projection*) es un algoritmo pensado exactamente para ese propósito: toma puntos que viven en un espacio de muchas dimensiones y calcula una proyección en dos dimensiones que intenta preservar, en la medida de lo posible, qué puntos estaban cerca entre sí y cuáles estaban lejos en el espacio original. No es una operación perfecta ni exacta (reducir de 1024 a 2 dimensiones necesariamente pierde información), pero funciona como una herramienta de inspección visual, ya que si en la proyección UMAP los puntos de dos especies forman dos nubes claramente separadas, es una señal razonable de que también estaban separadas en el espacio de 1024 dimensiones original. Si en cambio aparecen mezclados, es una señal de que los embeddings de esas dos especies son, al menos en parte, difíciles de distinguir entre sí.

En la siguiente figura se visualizan, para tres pares de especies del ranking de confusiones, los embeddings proyectados mediante UMAP. Cabe aclarar que los ejes “UMAP 1” y “UMAP 2” son simplemente las dos coordenadas de esa proyección bidimensional. Lo relevante a leer en estos gráficos es la posición relativa de los puntos entre sí, es decir, si los puntos de cada especie forman nubes separadas o si aparecen mezclados.




Figura 2: Proyección UMAP de los embeddings para tres pares de especies confundidas.

En los tres casos se observa algún grado de superposición entre las nubes de puntos de cada especie. La mayoría de los puntos de cada especie forman sus propios grupos bien diferenciados, y la mezcla ocurre solo en una región puntual del gráfico. Esta clase de superposición parcial sugiere que no es toda la vocalización de la especie la que resulta indistinguible de la otra, sino algún tipo de sonido específico compartido por ambas que la red codifica de manera similar.

Sin embargo, esta lectura de las “nubes” del gráfico es completamente cualitativa. Si queremos sacar conclusiones reales, hace falta entonces una métrica cuantitativa, calculada directamente sobre los embeddings originales y no sobre su proyección visual. Esto nos permitirá determinar con precisión si la red es o no capaz de separar cada par de especies.

5.3. Métrica cuantitativa: separabilidad lineal

La pregunta que se busca responder de forma cuantitativa es la siguiente: dado el embedding de 1024 dimensiones de cada grabación, ¿existe una manera simple de trazar una frontera que separe los puntos de una especie de los de la otra? La forma más simple posible de trazar esa frontera es una línea recta (o, en 1024 dimensiones, su equivalente, un hiperplano). Si una línea recta alcanza para separar razonablemente bien ambas nubes de puntos, diremos que el par de especies es *linealmente separable* en el espacio de embeddings.

Para medir esto se entrena un clasificador de regresión logística, el modelo estadístico más

simple capaz de aprender ese tipo de frontera lineal. A partir de los embeddings de entrenamiento, ajusta los coeficientes de una única línea (o hiperplano) que mejor separa ambas clases, y después la usa para clasificar puntos nuevos que no vio durante el ajuste. Además, el resultado se evalúa con validación cruzada. Esto significa que los embeddings de cada par de especies se dividen en varios subconjuntos, se entrena el clasificador con todos menos uno, se lo prueba sobre el subconjunto restante, y se repite el proceso rotando qué subconjunto queda afuera cada vez. Esto evita el problema de evaluar el modelo con los mismos datos que se usaron para ajustarlo, lo cual daría una idea artificialmente optimista de su desempeño. El resultado final es un valor de accuracy, es decir, el porcentaje de veces que el clasificador lineal acierta la especie correcta sobre datos que no usó para entrenarse.

La Figura 3 ilustra este procedimiento paso a paso sobre un ejemplo simplificado en dos dimensiones (en lugar de las 1024 dimensiones reales, para poder graficarlo). Primero se tienen los embeddings de ambas especies sin ninguna división. Estos se reparten aleatoriamente en varios subconjuntos, llamados pliegues. Se entrena el clasificador usando todos los pliegues menos uno, que queda completamente reservado y no participa del ajuste. Finalmente, se evalúa la frontera aprendida sobre ese pliegue reservado, marcando cada punto según si la predicción fue correcta o incorrecta. Este proceso se repite rotando cuál pliegue queda afuera cada vez, y el accuracy final que se reporta es el promedio de las repeticiones.




Figura 3: Ejemplo en dos dimensiones del procedimiento de validación cruzada usado para medir la separabilidad lineal.

Un valor de accuracy cercano al 100 % indica que las dos nubes de puntos son fácilmente separables con una línea recta. Un valor cercano al 50 % indica que la línea recta no logra distinguirlas mejor que una elección al azar entre las dos especies. La Figura 4 muestra ambos extremos lado a lado, sobre datos sintéticos: un caso donde las nubes están bien diferenciadas y la frontera lineal las separa con precisión, y un caso donde las nubes están mezcladas y la frontera lineal no logra distinguirlas mejor que el azar.




Figura 4: Comparación, sobre datos sintéticos, entre un caso linealmente separable y un caso no separable.

Elegir específicamente un clasificador lineal, y no uno más sofisticado capaz de trazar fronteras curvas o más complejas, no es una limitación técnica sino una decisión motivada directamente por cómo funciona el reentrenamiento que se aplicará más adelante. El modo *Append* de BirdNET-Analyzer, la estrategia de reentrenamiento que consideraremos en este trabajo, no modifica la forma en que el modelo calcula los embeddings. Mantiene esa parte de la red exactamente como está, y únicamente entrena una nueva capa de decisión final sobre los embeddings ya existentes. Esta nueva capa que es, en esencia, un clasificador lineal. Por eso esta métrica no es una medida de separabilidad genérica, sino una que responde exactamente a la pregunta relevante para este proyecto. Si el par de especies resulta ser linealmente separable, es razonable esperar que el modo *Append*, con suficientes datos de entrenamiento, logre corregir la confusión. Si en cambio ni siquiera un clasificador lineal logra separarlas, la información necesaria para distinguirlas no está disponible en el embedding, y ningún reentrenamiento de la capa de decisión final podría solucionarlo. Haría falta modificar las capas más profundas de la red, encargadas de calcular el embedding en sí.

5.4. Tabla completa de separabilidad para todos los pares

Se aplicó este procedimiento a los 164 pares del ranking de confusiones completo, no solo a los tres casos ilustrativos de la subsección anterior. Para cada par, se descargaron grabaciones de referencia de ambas especies, se calcularon sus embeddings, y se midió la separabilidad lineal siguiendo exactamente la misma metodología. De los 164 pares, 6 no pudieron evaluarse por falta de grabaciones de referencia suficientes para uno de los dos miembros del par. Tres de ellos corresponden a especies genuinamente raras en el repositorio de cantos o mal catalogadas en el mismo (*Apus melba*, *Gallirallus philippensis*, *Dryobates villosus*); dos involucran la categoría “Human vocal”, una etiqueta que BirdNET usa para voz humana de fondo y no para una especie

de ave, por lo cual no tiene sentido calcularle un embedding comparable; y el sexto es el caso ya mencionado de *Veniliornis mixtus* frente a *Dryobates mixtus*, el mismo desajuste de nomenclatura taxonómica discutido en la sección anterior. Estos 6 pares se excluyeron directamente de la tabla siguiente, ya que debido a lo explicado no llegaron a evaluarse. La tabla resume el resultado para cada par: el porcentaje de confusión original reportado por BirdNET, el accuracy de separabilidad lineal obtenido, y una categoría asignada según ese valor (separable si el accuracy es igual o mayor a 90 %, no separable si es igual o menor a 65 %, y parcialmente separable en el rango intermedio).

Tabla 4: Separabilidad lineal (accuracy con validación cruzada) para cada par de especies confundidas.

Especie real	Confundida con	Confusión BirdNET (%)	Separabilidad (%)	Categoría
<i>Geothlypis velata</i>	<i>Geothlypis aequinoctialis</i>	80.0	98.7	separable
<i>Chroicocephalus maculipennis</i>	<i>Chroicocephalus ridibundus</i>	50.0	99.5	separable
<i>Anas flavirostris</i>	<i>Anas crecca</i>	40.0	100.0	separable
<i>Anas georgica</i>	<i>Anas acuta</i>	37.5	100.0	separable
<i>Ardea cocoi</i>	<i>Ardea herodias</i>	30.0	97.3	separable
<i>Callonetta leucophrys</i>	<i>Sturnus unicolor</i>	30.0	99.8	separable
<i>Egretta thula</i>	<i>Egretta caerulea</i>	30.0	94.2	separable
<i>Falco sparverius</i>	<i>Falco columbarius</i>	30.0	100.0	separable
<i>Fulica leucoptera</i>	<i>Fulica atra</i>	37.5	99.2	separable
<i>Hymenops perspicillatus</i>	<i>Sicalis luteola</i>	33.3	97.6	separable
<i>Larus dominicanus</i>	<i>Larus argentatus</i>	30.0	99.2	separable
<i>Mycteria americana</i>	<i>Ardea alba</i>	30.0	99.6	separable
<i>Progne elegans</i>	<i>Progne chalybea</i>	30.0	99.7	separable
<i>Spatula cyanoptera</i>	<i>Fulica americana</i>	30.0	100.0	separable
<i>Sporophila caerulescens</i>	<i>Sporophila nigricollis</i>	30.0	99.1	separable
<i>Sterna hirundinacea</i>	<i>Thalasseus sandvicensis</i>	30.0	100.0	separable
<i>Tringa melanoleuca</i>	<i>Tringa flavipes</i>	30.0	97.8	separable
<i>Butorides striata</i>	<i>Butorides virescens</i>	20.0	96.4	separable
<i>Caracara plancus</i>	<i>Pica pica</i>	20.0	99.3	separable
<i>Chloroceryle americana</i>	<i>Opisthocomus hoazin</i>	20.0	99.4	separable
<i>Cinclodes fuscus</i>	<i>Asthenes pyrrholeuca</i>	20.0	99.6	separable
<i>Circus buffoni</i>	<i>Rallus limicola</i>	20.0	100.0	separable
<i>Cyclarhis gujanensis</i>	<i>Cyclarhis nigristrois</i>	20.0	99.3	separable
<i>Fulica armillata</i>	<i>Chroicocephalus maculipennis</i>	20.0	95.8	separable
<i>Fulica rufifrons</i>	<i>Podiceps cristatus</i>	20.0	100.0	separable
<i>Heteronetta atricapilla</i>	<i>Phleocryptes melanops</i>	40.0	99.1	separable
<i>Himantopus mexicanus</i>	<i>Zenaida asiatica</i>	20.0	99.3	separable
<i>Hylocharis chrysura</i>	<i>Urosphena squameiceps</i>	20.0	100.0	separable
<i>Leistes loyca</i>	<i>Rhopospina fruticeti</i>	20.0	98.4	separable
<i>Mimus saturninus</i>	<i>Mimus gilvus</i>	20.0	99.0	separable
<i>Molothrus rufoaxillaris</i>	<i>Linaria flavirostris</i>	20.0	99.4	separable
<i>Phimosus infuscatus</i>	<i>Amauornis moluccana</i>	20.0	100.0	separable
<i>Pitangus sulphuratus</i>	<i>Tolmomyias flaviventris</i>	20.0	99.4	separable
<i>Podiceps major</i>	<i>Calidris alpina</i>	20.0	99.4	separable
<i>Rauenia bonariensis</i>	<i>Hemithraupis guira</i>	22.2	99.7	separable

continúa en la página siguiente

Tabla 4 – continuación

Especie real	Confundida con	Confusión BirdNET (%)	Separabilidad (%)	Categoría
<i>Rollandia rolland</i>	<i>Aythya collaris</i>	50.0	100.0	separable
<i>Rupornis magnirostris</i>	<i>Amazona auropalliata</i>	20.0	98.6	separable
<i>Spatula versicolor</i>	<i>Calidris melanotos</i>	33.3	99.3	separable
<i>Sterna trudeaui</i>	<i>Phleocryptes melanops</i>	20.0	99.4	separable
<i>Tachycineta leucopyga</i>	<i>Cichlocolaptes leucophrys</i>	20.0	100.0	separable
<i>Tachycineta leucorrhoa</i>	<i>Stelgidopteryx serripennis</i>	22.2	100.0	separable
<i>Tigrisoma lineatum</i>	<i>Megascops watsonii</i>	20.0	99.8	separable
<i>Acridotheres cristatellus</i>	<i>Acridotheres tristis</i>	10.0	100.0	separable
<i>Agelaioides badius</i>	<i>Sitta europaea</i>	10.0	100.0	separable
<i>Agelasticus thilius</i>	<i>Anthus lutescens</i>	10.0	97.7	separable
<i>Amblyramphus holosericeus</i>	<i>Sporophila leucoptera</i>	10.0	99.2	separable
<i>Ammodramus humeralis</i>	<i>Artemisiospiza belli</i>	10.0	99.8	separable
<i>Anas bahamensis</i>	<i>Anthus pratensis</i>	11.1	99.5	separable
<i>Anser anser</i>	<i>Fulmarus glacialis</i>	10.0	100.0	separable
<i>Anthus correndera</i>	<i>Anthus hellmayri</i>	10.0	99.0	separable
<i>Aramides ypecaha</i>	<i>Agelaioides badius</i>	10.0	99.1	separable
<i>Aratinga nenday</i>	<i>Empidonax hammondi</i>	11.1	99.7	separable
<i>Ardea alba</i>	<i>Ardea cinerea</i>	10.0	97.5	separable
<i>Athene cunicularia</i>	<i>Sicalis flaveola</i>	10.0	100.0	separable
<i>Basileuterus culicivorus</i>	<i>Crypturellus undulatus</i>	10.0	99.5	separable
<i>Brotogeris chiriri</i>	<i>Brotogeris tirica</i>	10.0	95.6	separable
<i>Bubulcus ibis</i>	<i>Gallinago imperialis</i>	10.0	99.8	separable
<i>Cacicus solitarius</i>	<i>Icterus icterus</i>	10.0	97.7	separable
<i>Calidris alba</i>	<i>Vireo vicinior</i>	10.0	100.0	separable
<i>Calidris fuscicollis</i>	<i>Anthus pratensis</i>	10.0	98.8	separable
<i>Calidris melanotos</i>	<i>Anas platyrhynchos</i>	10.0	100.0	separable
<i>Charadrius falklandicus</i>	<i>Actitis macularius</i>	16.7	97.8	separable
<i>Chauna torquata</i>	<i>Brotogeris jugularis</i>	10.0	99.3	separable
<i>Chlorostilbon lucidus</i>	<i>Acrocephalus scirpaceus</i>	10.0	100.0	separable
<i>Chroicocephalus cirrocephalus</i>	<i>Chroicocephalus novaehollandiae</i>	10.0	99.5	separable
<i>Chrysomus ruficapillus</i>	<i>Guira guira</i>	10.0	99.8	separable
<i>Cistothorus platensis</i>	<i>Cistothorus palustris</i>	10.0	100.0	separable
<i>Coccyzus melacoryphus</i>	<i>Callipepla gambelii</i>	11.1	99.8	separable
<i>Colaptes campestris</i>	<i>Attila bolivianus</i>	10.0	99.2	separable
<i>Colaptes melanochloros</i>	<i>Agelaioides badius</i>	10.0	98.9	separable
<i>Columbina picui</i>	<i>Patagioenas plumbea</i>	12.5	100.0	separable
<i>Cygnus melancoryphus</i>	<i>Podiceps gallardoi</i>	10.0	98.7	separable
<i>Dendrocygna bicolor</i>	<i>Scleroptila gutturalis</i>	11.1	99.4	separable
<i>Dendrocygna viduata</i>	<i>Tringa ochropus</i>	10.0	100.0	separable
<i>Donacospiza albifrons</i>	<i>Melospiza kieneri</i>	10.0	99.5	separable
<i>Elaenia parvirostris</i>	<i>Cnemidicetus fuscatus</i>	10.0	99.2	separable
<i>Elanus leucurus</i>	<i>Gnorimopsar chopi</i>	10.0	99.6	separable
<i>Embernagra platensis</i>	<i>Emberiza pusilla</i>	10.0	98.9	separable
<i>Falco femoralis</i>	<i>Athene noctua</i>	10.0	100.0	separable
<i>Furnarius rufus</i>	<i>Pitangus sulphuratus</i>	10.0	99.2	separable

continúa en la página siguiente

Tabla 4 – continuación

Especie real	Confundida con	Confusión BirdNET (%)	Separabilidad (%)	Categoría
<i>Gallinula chloropus</i>	<i>Acrocephalus stentoreus</i>	10.0	99.1	separable
<i>Guira guira</i>	<i>Eupetomena macroura</i>	10.0	99.7	separable
<i>Haematopus palliatus</i>	<i>Haematopus ostralegus</i>	10.0	100.0	separable
<i>Hirundo rustica</i>	<i>Motacilla flava</i>	10.0	99.5	separable
<i>Icterus pyrrhopterus</i>	<i>Acrocephalus australis</i>	10.0	99.5	separable
<i>Jacana jacana</i>	<i>Butorides virescens</i>	10.0	99.7	separable
<i>Laterallus melanophaius</i>	<i>Amazona amazonica</i>	10.0	99.7	separable
<i>Leistes superciliaris</i>	<i>Leistes militaris</i>	10.0	97.9	separable
<i>Lepidocolaptes angustirostris</i>	<i>Furnarius rufus</i>	10.0	97.5	separable
<i>Leptasthenura platensis</i>	<i>Cranioleuca pyrrhophia</i>	10.0	98.0	separable
<i>Leptotila verreauxi</i>	<i>Pyrrhura frontalis</i>	10.0	99.3	separable
<i>Lessonia rufa</i>	<i>Artemisiospiza nevadensis</i>	16.7	99.6	separable
<i>Limnortites sulphuriferus</i>	<i>Leistes superciliaris</i>	10.0	99.7	separable
<i>Limnornis curvirostris</i>	<i>Limnortites sulphuriferus</i>	10.0	99.5	separable
<i>Limosa haemastica</i>	<i>Attagis gayi</i>	10.0	99.4	separable
<i>Mareca sibilatrix</i>	<i>Gallinula galeata</i>	10.0	99.7	separable
<i>Megascops choliba</i>	<i>Athene noctua</i>	10.0	100.0	separable
<i>Microspingus cabanisi</i>	<i>Carduelis carduelis</i>	10.0	99.7	separable
<i>Microspingus melanoleucus</i>	<i>Ploceus manyar</i>	10.0	100.0	separable
<i>Milvago chimango</i>	<i>Buteo jamaicensis</i>	10.0	99.2	separable
<i>Mimus triurus</i>	<i>Cincloramphus timoriensis</i>	10.0	100.0	separable
<i>Molothrus bonariensis</i>	<i>Dysithamnus occidentalis</i>	10.0	99.7	separable
<i>Myiodynastes maculatus</i>	<i>Clibanornis dendrocolaptoides</i>	10.0	99.5	separable
<i>Myiophobus fasciatus</i>	<i>Dryocopus lineatus</i>	10.0	97.8	separable
<i>Nannopterum brasilianum</i>	<i>Euphonia chlorotica</i>	10.0	99.8	separable
<i>Netta peposaca</i>	<i>Chiroxiphia caudata</i>	16.7	100.0	separable
<i>Parabuteo unicinctus</i>	<i>Asio otus</i>	10.0	99.8	separable
<i>Paroaria capitata</i>	<i>Acrocephalus paludicola</i>	11.1	100.0	separable
<i>Paroaria coronata</i>	<i>Agelaioides badius</i>	10.0	99.8	separable
<i>Passer domesticus</i>	<i>Falco naumanni</i>	10.0	99.8	separable
<i>Patagioenas picazuro</i>	<i>Apaloderma narina</i>	10.0	100.0	separable
<i>Phacellodomus striaticollis</i>	<i>Phacellodomus sibilatrix</i>	10.0	98.6	separable
<i>Phleocryptes melanops</i>	<i>Certhiaxis cinnamomeus</i>	10.0	98.3	separable
<i>Phoenicopterus chilensis</i>	<i>Anser canagicus</i>	11.1	98.3	separable
<i>Phylloscartes ventralis</i>	<i>Basileuterus culicivorus</i>	10.0	97.5	separable
<i>Phytotoma rutila</i>	<i>Argya malcolmi</i>	10.0	100.0	separable
<i>Piranga flava</i>	<i>Cariama cristata</i>	11.1	99.5	separable
<i>Platalea ajaja</i>	<i>Coragyps atratus</i>	10.0	100.0	separable
<i>Plegadis chihi</i>	<i>Mycteria americana</i>	10.0	99.5	separable
<i>Pluvialis dominica</i>	<i>Pluvialis fulva</i>	10.0	100.0	separable

continúa en la página siguiente

Tabla 4 – continuación

Especie real	Confundida con	Confusión BirdNET (%)	Separabilidad (%)	Categoría
<i>Poliophtila duminicola</i>	<i>Actitis macularius</i>	10.0	98.8	separable
<i>Poospiza nigrorufa</i>	<i>Vanellus senegallus</i>	10.0	99.5	separable
<i>Porphyriops melanops</i>	<i>Asthenes coryi</i>	10.0	98.9	separable
<i>Progne tapera</i>	<i>Curruca communis</i>	10.0	99.1	separable
<i>Pseudocolopteryx flaviventris</i>	<i>Chloroceryle amazona</i>	11.1	100.0	separable
<i>Psittacara leucophthalmus</i>	<i>Brotogetis chiriri</i>	10.0	98.2	separable
<i>Pygochelidon cyanoleuca</i>	<i>Auriparus flaviceps</i>	11.1	98.8	separable
<i>Pyrocephalus rubinus</i>	<i>Zonotrichia capensis</i>	10.0	99.0	separable
<i>Rhea americana</i>	<i>Aramides ypecaha</i>	10.0	99.1	separable
<i>Rhynchotus rufescens</i>	<i>Fulica atra</i>	10.0	99.4	separable
<i>Rostrhamus sociabilis</i>	<i>Aramus guarauna</i>	10.0	99.4	separable
<i>Saltator coerulescens</i>	<i>Furnarius rufus</i>	10.0	97.8	separable
<i>Saltator similis</i>	<i>Ilicura militaris</i>	10.0	98.3	separable
<i>Satrapa icterophrys</i>	<i>Andropadus importunus</i>	11.1	99.6	separable
<i>Serpophaga griseicapilla</i>	<i>Apus pallidus</i>	10.0	100.0	separable
<i>Serpophaga nigricans</i>	<i>Aeronautes montivagus</i>	11.1	98.5	separable
<i>Serpophaga subcristata</i>	<i>Cranioleuca pyrrhophia</i>	10.0	99.7	separable
<i>Setophaga pitiaiyumi</i>	<i>Amazona mercenarius</i>	10.0	99.8	separable
<i>Sicalis luteola</i>	<i>Emberiza coides</i>	10.0	99.5	separable
<i>Spartonoica maluioides</i>	<i>Anthus correndera</i>	10.0	99.6	separable
<i>Spinus magellanicus</i>	<i>Camaroptera brachyura</i>	10.0	98.4	separable
<i>Stephanophorus diadematus</i>	<i>Cyclarhis gujanensis</i>	10.0	98.0	separable
<i>Sturnus vulgaris</i>	<i>Buteo buteo</i>	10.0	99.6	separable
<i>Syrigma sibilatrix</i>	<i>Burhinus oedicnemus</i>	10.0	100.0	separable
<i>Tachuris rubrigastra</i>	<i>Phleocryptes melanops</i>	10.0	97.0	separable
<i>Thalasseus maximus</i>	<i>Arenaria interpres</i>	10.0	100.0	separable
<i>Thamnophilus caerulescens</i>	<i>Chiroxiphia caudata</i>	10.0	98.8	separable
<i>Thraupis sayaca</i>	<i>Euphonia violacea</i>	10.0	97.5	separable
<i>Tringa flavipes</i>	<i>Colaptes melanochloros</i>	10.0	99.7	separable
<i>Troglodytes aedon</i>	<i>Anthus trivialis</i>	10.0	100.0	separable
<i>Turdus rufiventris</i>	<i>Agelaioides badius</i>	10.0	99.7	separable
<i>Tyrannus melancholicus</i>	<i>Campylorhynchus turdinus</i>	10.0	99.2	separable
<i>Tyto alba</i>	<i>Procnias albus</i>	10.0	99.7	separable
<i>Vanellus chilensis</i>	<i>Accipiter gentilis</i>	10.0	99.7	separable
<i>Vireo chivi</i>	<i>Columbina squammata</i>	10.0	99.6	separable
<i>Xolmis irupero</i>	<i>Grallaria quitensis</i>	11.1	98.9	separable
<i>Zenaida auriculata</i>	<i>Dryobates pubescens</i>	10.0	99.6	separable
<i>Zonotrichia capensis</i>	<i>Chlorornis riefferii</i>	10.0	100.0	separable

De los 158 pares que sí pudieron evaluarse, la totalidad resultó separable según el criterio adoptado, pues en ningún caso el accuracy de separabilidad lineal bajó de 94 %. Esto significa que, para las 158 confusiones más frecuentes identificadas en el diagnóstico, el embedding de BirdNET ya contiene la información necesaria para distinguir cada par de especies, y el problema no está en la representación interna de la red sino en su capa de decisión final. Este resultado justifica que la estrategia de reentrenamiento no modifique las capas profundas del

modelo, dado que alcanza con reentrenar la capa de clasificación final sobre los embeddings ya existentes.

6. Conclusión del diagnóstico

El diagnóstico desarrollado en esta primera parte responde las dos preguntas planteadas en la introducción. Sobre cuánto se equivoca el modelo y con qué patrón, la respuesta es un accuracy baseline del 63.6 % sobre las 193 especies objetivo, con errores que no son aleatorios sino concentrados en confusiones intra-genéricas, además de algunos casos que cruzan geografías completas sin relación biológica cercana, consistentes con la hipótesis de sesgo geográfico planteada al inicio.

Sobre en qué etapa del modelo se origina ese error, el análisis de separabilidad lineal sobre los 158 pares evaluables dio una respuesta concreta. En todos los casos, un clasificador lineal simple distingue ambas especies con al menos 94 % de accuracy, lo cual indica que el embedding ya contiene la información necesaria y que el problema está concentrado en la capa de decisión final, no en la representación interna.

Esto tiene una consecuencia directa. **No hace falta modificar las capas profundas de la red, alcanza con entrenar una nueva capa de decisión final sobre los embeddings existentes usando datos locales.** La Parte II de este informe documenta ese proceso de reentrenamiento.

Parte II

Reentrenamiento

7. Arquitectura de BirdNET y estrategias de reentrenamiento

Antes de entrar en el proceso de reentrenamiento en sí, conviene detenerse un momento a entender mejor cómo está armada la red que se va a modificar, y qué significa concretamente “reentrenarla”. Esta sección resume, en términos generales, cómo BirdNET transforma un audio en una predicción, y qué opciones existen para adaptar ese proceso a un contexto nuevo como el de este proyecto.

7.1. De la grabación a la predicción

Una red neuronal, en su forma más básica, es una función matemática con una enorme cantidad de números ajustables, llamados *parámetros* o *pesos*, que transforma una entrada (en este caso, un audio) en una salida (en este caso, una lista de probabilidades, una por especie posible). Esos números no se programan a mano: se ajustan automáticamente durante un proceso llamado *entrenamiento*, en el que se le muestra a la red una enorme cantidad de ejemplos ya etiquetados (grabaciones cuya especie ya se conoce), se mide cuánto se equivoca en cada uno, y se corrigen los parámetros, de a poquito y muchísimas veces, en la dirección que reduce ese error. BirdNET fue entrenado de esta manera con millones de grabaciones de aves de todo el mundo.

Como se explicó en la Parte I (Sección 5.1), BirdNET no hace esta transformación en un único paso, sino en dos etapas bien diferenciadas. La Figura 5 las resume de forma esquemática.




Figura 5: Esquema del *pipeline* de BirdNET: de la grabación de audio a la especie predicha. El extractor de características es la parte “cara” de entrenar, y se mantiene sin cambios; la capa de decisión es mucho más simple, y es la única parte que se modifica en este reentrenamiento.

La primera etapa, el *extractor de características*, es una red neuronal profunda (compuesta por muchas capas internas, cada una procesando la salida de la anterior) que recibe la grabación de 3 segundos y la transforma en el embedding: la lista de 1024 números que funciona como una huella digital acústica del sonido. Esta etapa es, en la práctica, la parte más costosa y sofisticada de la red, la que realmente “aprendió a escuchar” (a distinguir timbres, ritmos, patrones de frecuencia) a partir de millones de ejemplos.

La segunda etapa, la *capa de decisión*, es mucho más simple: toma esos 1024 números y los combina, de forma de producir un puntaje para cada especie del catálogo, uno por cada “neurona” de salida. Cada una de esas neuronas tiene su propia receta: multiplica cada uno de los 1024 números del embedding por un peso propio, suma todo, y aplica una función *sigmoide*, que convierte ese resultado en un valor entre 0 y 1 (una probabilidad). La especie cuya neurona produce el valor más alto es la predicción top-1 usada en todo este informe.

7.2. Qué significa reentrenar esta red

Reentrenar una red neuronal desde cero, ajustando sus millones de parámetros contra los datos locales disponibles para este proyecto, no es viable: haría falta una cantidad de grabaciones muchísimo mayor a la que existe en Xeno-canto para estas especies, además de un poder de cómputo considerable. Por suerte, no hace falta ir tan lejos. Como el propio diagnóstico de la Parte I mostró (Sección 5.4), el embedding que produce el extractor de características ya contiene, para prácticamente todos los pares de especies confundidas, la información necesaria para distinguirlas: un clasificador lineal simple entrenado sobre esos embeddings alcanzaba más de 94 % de accuracy en todos los casos evaluados. Esto significa que el problema no está en cómo la red “escucha” el audio, sino en cómo, a partir de eso, decide a qué especie asignarlo. Es decir, el problema está concentrado en la capa de decisión, la segunda etapa de la Figura 5.

Esto habilita una estrategia mucho más económica, conocida en general como *transferencia de aprendizaje* (*transfer learning*): dejar el extractor de características tal cual está y reentrenar exclusivamente la capa de decisión, usando datos locales. BirdNET-Analyzer, la herramienta oficial para reentrenar BirdNET, ofrece dos formas de incorporar esa capa nueva. La primera, modo *Replace*, descarta por completo las neuronas de salida del catálogo global (miles de especies de todo el mundo) y las reemplaza enteramente por un conjunto nuevo, con una única neurona por cada una de las 193 especies locales elegidas: el resultado es una capa de decisión mucho más chica, entrenada desde cero, que sólo puede reconocer esas 193 especies. La segunda, modo *Append*, en cambio conserva el catálogo global intacto (sin reentrenar) y simplemente le agrega las 193 neuronas nuevas al lado, sin descartar nada: las salidas quedan compitiendo todas juntas, catálogo global más especies locales, por el primer lugar.

La elección entre *Replace* y *Append* no es un detalle técnico menor: depende directamente de para qué se va a usar el modelo resultante. En este proyecto se optó por *Append*, ya que el LSD-Tector, aunque está pensado principalmente para identificar la avifauna de una región puntual de Argentina, también puede eventualmente grabar alguna especie de paso, vagante o simplemente no contemplada en la lista de 193, y descartar por completo la posibilidad de reconocerla hubiera sido un costo demasiado alto para un dispositivo de campo. *Append* preserva esa posibilidad sin sacrificar el trabajo de especializar la capa de decisión: las 193 neuronas nuevas siguen entrenándose exactamente igual que si se fuera a usar *Replace*, y sólo cambia cómo se las combina con el catálogo original al exportar el archivo final. La contrapartida es que la predicción top-1 ahora se elige por *argmax* entre miles de opciones en vez de sólo 193, lo cual introduce algo más de competencia para las especies locales; ese costo se cuantifica en la Sección 13.

Con esta decisión tomada, el resto de esta parte del informe describe, en dos intentos sucesivos, cómo se construyó y entrenó esa nueva capa de decisión.

8. Construcción del conjunto de entrenamiento

El diagnóstico de la Parte I sirvió para decidir qué estrategia de reentrenamiento aplicar, pero no incluyó ningún entrenamiento en sí. Los datos usados hasta ahora (el conjunto de va-

lidación de 10 grabaciones por especie) cumplieron un rol puramente evaluativo, y no pueden reutilizarse para entrenar: si el modelo reentrenado se evaluara luego sobre las mismas grabaciones que ya vio durante el entrenamiento, el resultado quedaría artificialmente inflado, ya que estaría siendo examinado con las respuestas que ya conoce. Por eso, antes de poder entrenar esta nueva capa de decisión, hizo falta construir un conjunto de datos completamente nuevo, separado del de validación, con volumen suficiente para que pueda aprender a distinguir cada especie.

Este conjunto se compone de dos tipos de ejemplos por especie. Los positivos son grabaciones reales de la propia especie objetivo, análogos a los usados en el diagnóstico pero en mayor cantidad. Los negativos duros son grabaciones de la especie con la que, según el ranking de confusiones de la Sección 4, más frecuentemente se la confunde. La inclusión de negativos duros no es un detalle menor: entrenar un clasificador solo con ejemplos positivos de cada clase no le enseña a distinguir especies parecidas entre sí, mientras que mostrarle explícitamente ejemplos del confusor más probable, etiquetados como negativos, es lo que le permite aprender exactamente la frontera que hace falta corregir.

Para cada una de las 193 especies se descargaron hasta 30 grabaciones positivas y hasta 15 grabaciones del confusor principal como negativos duros, ambas filtradas por calidad A o B en Xeno-canto, de la misma manera que en el conjunto de validación pero excluyendo cualquier grabación ya utilizada en aquella etapa. El flujo para cada grabación es descargarla, calcular su embedding con BirdNET, y borrar el archivo de audio inmediatamente después: el entrenamiento de esta nueva capa opera exclusivamente sobre embeddings, y en ningún momento se vuelve a necesitar el audio original.

El resultado fue un conjunto de 57724 embeddings cubriendo la totalidad de las especies objetivo, cada uno etiquetado con su tipo (positivo, o negativo duro junto con la especie confusora de la que proviene). Para entrenar, ese tipo se tradujo en una matriz con una fila por embedding y una columna por especie, donde cada celda vale 1, 0 o -1: un positivo marca con 1 la columna de su propia especie, mientras que un negativo duro marca con -1 la columna de la especie objetivo a la que ese confusor suele desplazar, ya que lo que se le enseña al clasificador en ese caso es que ese sonido no corresponde a la especie con la que habitualmente se lo confunde. El resto de las columnas queda en 0, ya que ese embedding no aporta información sobre las demás especies.

Al aplicar este esquema se obtuvieron 40384 entradas positivas y 17340 de negativo duro, que suman exactamente los 57724 embeddings totales, confirmando que cada ejemplo quedó representado una única vez en la matriz. Esta se guardó junto con los embeddings en el formato binario que la rutina de entrenamiento utiliza directamente, evitando reconstruirla cada vez que haga falta repetir o ajustar el entrenamiento.

9. Entrenamiento del clasificador

Con el conjunto de entrenamiento ya armado, quedaba ajustar los parámetros de la nueva capa de decisión descrita en la sección anterior: $1024 \times 193 + 193 = 197825$ números en total (un peso por cada combinación de las 1024 dimensiones del embedding con cada una de las 193 neuronas de salida, más un sesgo propio por neurona).

Ajustar estos parámetros es un proceso iterativo. Al principio, antes de ver ningún dato, esos 197825 números se inicializan con valores pequeños y aleatorios, así que las predicciones de la red son básicamente ruido: no tiene todavía ninguna razón para asignarle mayor puntaje a la especie correcta que a cualquier otra. El entrenamiento consiste en corregir eso de a poco: se le muestra a la red un grupo de embeddings, se compara lo que predijo con la etiqueta real de cada uno mediante una *función de pérdida* (una función que es grande cuando la predicción

está muy equivocada y chica cuando está cerca de la respuesta correcta), y se ajusta cada uno de los 197825 parámetros en la dirección que reduciría un poco ese número, un procedimiento llamado *descenso de gradiente*. Repitiendo este ciclo una y otra vez, mostrándole a la red el conjunto de entrenamiento completo muchas veces (cada pasada completa se llama una *época*), los parámetros van encontrando una combinación cada vez mejor.

En este esquema, los positivos y los negativos duros cumplen roles complementarios: cada positivo empuja hacia arriba el puntaje de la neurona de esa especie (“la próxima vez que veas algo así, subí tu puntaje”), mientras que cada negativo duro empuja hacia abajo, específicamente, el puntaje de la especie con la que se la suele confundir (“esto no es esa otra especie, aunque se le parezca”). Sin un negativo duro dedicado, la única señal disponible sobre lo que *no* es una especie es mucho más débil y difusa.

Concretamente, el ajuste se hizo con la rutina de entrenamiento estándar de BirdNET-Analyzer para este tipo de capa: hasta 150 épocas, deteniéndose antes si la pérdida sobre un conjunto de validación interno deja de mejorar (*parada temprana*), para evitar que la red memorice detalles específicos de las grabaciones de entrenamiento en lugar de aprender patrones que generalicen a audio nuevo. El optimizador (el algoritmo concreto que decide, en cada paso, cuánto y en qué dirección mover cada parámetro) fue Adam, una variante mejorada del descenso de gradiente estándar. Un 20 % de los embeddings se reservó para ese conjunto de validación interno, usado únicamente para decidir en qué época detener el entrenamiento, nunca para evaluar el resultado final, que se mide siempre sobre el conjunto de validación de la Parte I. El resultado es un único archivo `.tflite` que combina el extractor de características original (congelado, sin modificar) con esta nueva capa de decisión entrenada, listo para reemplazar directamente al clasificador que el dispositivo usa hoy.

10. Resultados del primer reentrenamiento

Con el clasificador ya entrenado, correspondía repetir exactamente el mismo procedimiento de evaluación de la Parte I (Sección 3): las mismas 1930 grabaciones de Xeno-canto reservadas como conjunto de validación (nunca usadas durante el entrenamiento), el mismo criterio de accuracy top-1, y el mismo binado para el histograma de distribución. Esta correspondencia exacta con el baseline es la que permite que la comparación sea directa y no esté sesgada por ningún cambio metodológico.




Figura 6: Distribución de accuracy top-1 antes y después del primer reentrenamiento (v1).

El resultado fue un salto considerable: el accuracy top-1 global pasó de 63.6 % a 85.2 %, y el

accuracy macro (el promedio simple entre las 193 especies, que a diferencia del global no les da más peso a las especies con más grabaciones de validación) subió de 62.6 % a 85.4 %. La Figura 6 compara la distribución completa de accuracy por especie antes y después de este primer reentrenamiento: donde antes había una cantidad considerable de especies repartidas en los tramos bajos e intermedios, ahora la enorme mayoría se concentra en el tramo de 90-100 %.

Sin embargo, un promedio que mejora mucho no garantiza que la mejora sea pareja entre las 193 especies, y de hecho no lo fue: 131 especies mejoraron respecto del baseline y 41 quedaron exactamente igual (accuracy de 100 % en ambos casos, en su mayoría), pero 21 especies terminaron con un accuracy *más bajo* que antes de reentrenar, algo que en principio no debería pasar: entrenar con más datos locales no debería empeorar el reconocimiento de una especie que ya se reconocía bien. La Tabla 5 muestra los diez casos más marcados.

Especie	Baseline (%)	v1 (%)	Diferencia
<i>Myiophobus fasciatus</i>	80.0	20.0	-60.0
<i>Sicalis flaveola</i>	100.0	60.0	-40.0
<i>Aramus guarauna</i>	100.0	80.0	-20.0
<i>Calidris alba</i>	90.0	70.0	-20.0
<i>Poospiza nigrorufa</i>	90.0	70.0	-20.0
<i>Troglodytes aedon</i>	70.0	50.0	-20.0
<i>Aramides cajaneus</i>	100.0	90.0	-10.0
<i>Athene cunicularia</i>	90.0	80.0	-10.0
<i>Butorides striata</i>	40.0	30.0	-10.0
<i>Carduelis carduelis</i>	100.0	90.0	-10.0

Tabla 5: Diez especies con el retroceso más marcado respecto del baseline tras el primer reentrenamiento (v1). En total, 21 de 193 especies quedaron por debajo del baseline.

El caso más extremo es *Myiophobus fasciatus*, que cae 60 puntos porcentuales (de 80 % a 20 %). Esta clase de retroceso puntual es lo que motivó la investigación de la sección siguiente: si el objetivo del reentrenamiento es mejorar el reconocimiento de la avifauna local sin introducir errores nuevos, hace falta entender por qué, en algunas especies, más datos locales terminaron produciendo un modelo peor.

11. Diagnóstico del retroceso en algunas especies

La primera pista surgió de cruzar estos retrocesos con la construcción del conjunto de entrenamiento descrita en la Sección 8. Ahí, para cada especie, los negativos duros se armaron a partir del confusor identificado en el ranking de la Sección 4. Pero ese ranking sólo pudo identificar un confusor para las especies que efectivamente tuvieron al menos un error en el conjunto de validación de 10 grabaciones del diagnóstico. Para 41 de las 193 especies, que llegaron al diagnóstico con 100 % de accuracy y por lo tanto sin ningún error registrado, nunca se identificó ningún confusor, y en consecuencia nunca recibieron un solo negativo duro durante el entrenamiento.

Separar las 193 especies según si contaron o no con al menos un negativo duro real revela un patrón claro: las 152 especies que sí tuvieron negativos duros mejoraron, en promedio, 27.15 puntos porcentuales respecto del baseline, y sólo 13 de ellas (8.6 %) terminaron por debajo de donde estaban. Las 41 especies sin ningún negativo duro, en cambio, mejoraron apenas 6.70 puntos en promedio, y 8 de ellas (19.5 %, más del doble de proporción) empeoraron. Ahí se concentra buena parte de los retrocesos de la Tabla 5: sin un ejemplo explícito de “esto no es esta especie”, el clasificador sólo cuenta con la señal difusa e indirecta de que el resto de las

57724 filas del conjunto de entrenamiento tampoco son esa especie, una señal mucho más débil que la de un negativo duro dedicado.

Frente a este diagnóstico, en lugar de simplemente agregarle a esas 41 especies un negativo duro sintético sobre el mismo esquema de entrenamiento, se optó por resolverlo de raíz junto con un cambio más profundo: la forma en que se entrena la capa final.

12. Un cambio de enfoque: reentrenar con regresión logística

En resumen, el entrenamiento descrito en la sección anterior era el siguiente: mostrarle ejemplos a la red, medir el error con una función de pérdida, y corregir los parámetros de a poco por descenso de gradiente. Este es el método estándar para entrenar redes neuronales, y funciona bien en general. Pero es, en cierto sentido, más de lo que este problema puntual necesita: fue diseñado para ajustar redes mucho más grandes y complejas que una simple capa lineal, avanza de a pasos aproximados, y no ofrece ninguna garantía de encontrar la mejor combinación posible de parámetros dentro del presupuesto de épocas disponible. Además, la función de pérdida particular que usa BirdNET-Analyzer para combinar positivos y negativos duros en una misma matriz (con valores 1, 0 y -1) es una herramienta genérica, pensada para cubrir muchos casos de uso distintos del paquete, y no está especialmente ajustada a este problema.

Vale la pena volver a un hecho ya mencionado: la capa de decisión nueva, tanto en modo Replace como en modo Append, es matemáticamente nada más que una regresión logística. Y una regresión logística no hace falta entrenarla por descenso de gradiente aproximado: existen herramientas dedicadas, pensadas específicamente para este tipo de problema, capaces de encontrar la mejor solución posible de forma directa. De hecho, ya se usó una de ellas en este mismo informe. A este segundo reentrenamiento lo llamaremos v2 de acá en adelante.

12.1. Qué es una regresión logística, en términos simples

Una regresión logística es, probablemente, la forma más simple que existe de enseñarle a una computadora a distinguir entre categorías. La idea es la misma que se introdujo en la Sección 5.3 del diagnóstico para medir separabilidad: para cada especie se busca una única línea recta (o, en 1024 dimensiones, su equivalente, un hiperplano) que separe lo mejor posible los embeddings de esa especie del resto. Concretamente, aprende un peso para cada una de las 1024 dimensiones del embedding (indicando cuánto le importa esa dimensión para reconocer a esa especie en particular) y un sesgo que corre la frontera para un lado u otro; combinando eso obtiene un puntaje que, cuanto más alto, más segura está de que el sonido le pertenece a esa especie.

Esto es exactamente lo mismo que hace la capa de decisión de BirdNET (una neurona lineal por especie, más una función que convierte el puntaje en una probabilidad), sólo que en la Sección 5.3 se entrenaba únicamente para medir, de a un par de especies por vez, si esa frontera podía existir. Ahora se trata de usar la misma herramienta, pero para las 193 especies a la vez, como la estrategia real de reentrenamiento.

12.2. Por qué conviene resolverlo así en vez de a los tumbos

La razón principal para preferir este enfoque es que el problema de ajustar una regresión logística tiene una propiedad muy conveniente: es *convexo*. En términos prácticos, esto significa que la función de pérdida que se busca minimizar tiene un único mínimo, sin otros mínimos

locales que puedan confundir al método de optimización. El descenso de gradiente de la sección anterior, en cambio, no ofrece esa garantía en general: si la función de pérdida tiene varios mínimos locales, el resultado final depende de la inicialización y del camino recorrido, y nada asegura que el punto donde se detiene sea el mejor posible. Cuando el problema es convexo, en cambio, cualquier punto donde el algoritmo deja de mejorar *es*, necesariamente, el óptimo global. Por eso tiene sentido usar una herramienta dedicada a resolver problemas convexos, como `scikit-learn` (la misma biblioteca ya usada en la Sección 5.3): en vez de aproximar la solución de a pasos, la calcula de forma directa, con la garantía de que es la mejor combinación de pesos posible para ese conjunto de entrenamiento.

Sumado a esto, esta herramienta ofrece dos ventajas prácticas adicionales sobre el entrenamiento de la sección anterior: una regularización ajustable de forma sistemática (un mecanismo que evita que el modelo se ajuste demasiado a las particularidades del conjunto de entrenamiento, eligiendo su intensidad mediante un conjunto de validación en vez de dejarla en un valor por defecto casi nulo), y un manejo estándar del desbalance de clases, que se explica en la próxima subsección.

12.3. Aprovechar mejor los datos: reetiquetado y balanceo de clases

Para poder usar esta herramienta hizo falta reorganizar el conjunto de entrenamiento. El esquema anterior (1 para positivo, -1 para negativo duro, 0 para el resto) le permitía a una misma fila decir cosas distintas sobre columnas distintas a la vez; una regresión logística estándar, en cambio, espera que cada fila tenga una única etiqueta verdadera: la especie a la que realmente pertenece esa grabación.

Esto en realidad resultó una oportunidad para aprovechar mejor los datos ya recolectados. Las grabaciones usadas como negativos duros no son audio inventado, sino que son grabaciones reales de la especie confusora, descargadas específicamente porque se parecía a la especie objetivo. Hasta ahora sólo se les había dicho a esas grabaciones lo que *no* eran (“esto no es la especie objetivo”); en este reordenamiento se las etiquetó, en cambio, con lo que genuinamente *son* (la especie confusora), sumándose como ejemplos positivos genuinos de esa especie. Es información más directa y más rica que la anterior, y no hizo falta descargar ni un solo audio nuevo para conseguirla. Los pocos casos en los que el confusor no correspondía a ninguna de las 193 especies objetivo (por ejemplo, la categoría “Human vocal” que usa BirdNET para voz humana de fondo) se descartaron, al no tener una clase válida entre las 193 salidas. El resultado fue un conjunto de 43214 embeddings, cada uno con una única etiqueta real, con entre 21 y 833 ejemplos por especie.

El otro ajuste fue el balanceo de clases. Como algunas especies terminaron con muchos más ejemplos que otras, sin ninguna corrección el entrenamiento le prestaría más atención, en promedio, a las especies con más datos, simplemente porque contribuyen más términos a la cuenta del error total. Para evitar eso, se le asignó a cada especie un peso inversamente proporcional a la cantidad de ejemplos que tiene, de forma que una especie con pocos ejemplos cuente, en conjunto, tanto como una con muchos. La fuerza de regularización mencionada en la subsección anterior se eligió, a su vez, comparando dos valores candidatos sobre un conjunto de validación interno, quedándose con el que mejor generalizaba.

12.4. Por qué entrenar pensando en un único ganador

Hay una última diferencia, más sutil, entre este entrenamiento y el de la sección anterior. La capa de decisión de BirdNET trata a las 193 especies como 193 preguntas de sí-o-no independientes entre sí (“¿es esta especie? sí o no”, repetido 193 veces), sin que compitan directamente entre ellas durante el entrenamiento. Pero el uso real que se le da al modelo sí las hace

competir, pues al final sólo importa cuál de las 193 tuvo el puntaje más alto. Por eso, en este reentrenamiento se usó una variante, llamada *multinomial*, o *softmax*, que entrena a las 193 especies compitiendo entre sí desde el principio, repartiendo la “responsabilidad” de cada ejemplo entre todas ellas en simultáneo, en lugar de evaluarlas una por una sin que se enteren de las demás. Esto está más alineado con cómo se va a usar el modelo en la práctica.

Una aclaración importante: al desplegarse en BirdNET, las 193 salidas igual pasan por la misma transformación tipo-sigmoide que se usó en el primer reentrenamiento, no por una softmax. Esto podría parecer una contradicción, pero no lo es: softmax y sigmoide son apenas dos formas distintas de convertir puntajes en algo parecido a una probabilidad, pero ambas son *funciones crecientes* (si un puntaje era más alto que otro antes de la transformación, lo sigue siendo después), y se aplican por igual a las 193 salidas. Es como comparar las alturas de un grupo de personas en metros o en pies: cambia la escala, pero el orden de quién es más alto no cambia. Como el único criterio que importa en este informe es top-1 (quién queda primero), entrenar pensando en la competencia entre las 193 especies (softmax) y desplegar con la transformación sigmoide de BirdNET son perfectamente compatibles.

12.5. De los pesos aprendidos al archivo que usa la Raspberry Pi

El resultado de este ajuste son, igual que antes, 197825 números: un peso para cada una de las 1024 dimensiones del embedding, por cada una de las 193 especies, más un sesgo por especie. La diferencia es únicamente cómo se llegó a esos números, no lo que se hace con ellos después: se insertan en una capa con exactamente la misma arquitectura que ya se usaba (Figura 5), y se exportan en modo Append con la misma rutina de guardado de BirdNET-Analyzer, concatenando esta capa nueva de 193 salidas con la capa original de 6522 especies (sin modificar). El resultado es un único archivo .tflite con 6715 salidas en total, que sigue siendo, para la Raspberry Pi, exactamente el mismo tipo de archivo que ya sabe correr: sólo cambia cuántas neuronas de salida tiene.

El resultado final de toda esta parte del informe es entonces un único archivo, autocontenido, con tres piezas encadenadas:

1. El *extractor de características* original de BirdNET (Figura 5), sin ningún cambio: sigue siendo la red que convierte cada ventana de 3 segundos de audio en un embedding de 1024 números.
2. La *capa de decisión original* de BirdNET, también sin ningún cambio: las 6522 neuronas que reconocen el catálogo global de especies, tal como las entrenó el equipo de BirdNET.
3. La *capa de decisión nueva*, las 193 neuronas entrenadas en esta sección con regresión logística sobre datos locales, puestas al lado de las anteriores en vez de reemplazarlas.

Las tres piezas quedan combinadas en un solo grafo de TensorFlow Lite, con 6715 salidas en total: para cada grabación, el archivo sigue produciendo una única lista de puntajes, uno por especie, de la cual se toma el más alto como predicción top-1. Ese archivo es el que se evalúa en la sección siguiente y el que finalmente se instala en la Raspberry Pi del LSD-Tector.

13. Resultados finales y elección del modelo

Repitiendo una vez más el mismo procedimiento de evaluación sobre el mismo conjunto de validación, v2 alcanzó un accuracy top-1 global de 85.7 % y un accuracy macro de 86.0 %, superando al primer intento en ambas métricas agregadas (Tabla 6). Esta cifra ya incluye el

costo de competencia mencionado en la Sección 7: la predicción top-1 se elige entre las 6715 salidas del archivo final (catálogo global más las 193 especies locales), no sólo entre las 193, así que representa directamente el desempeño real del archivo que corre en la Raspberry Pi.

Ese costo, en la práctica, resultó nulo. Revisando las 1880 grabaciones evaluadas, en ningún caso una especie del catálogo global le ganó el primer lugar a la especie local correcta: cada vez que la predicción falló, el error siguió siendo entre dos especies locales, exactamente el mismo patrón de confusión que ya se ve en la Tabla 7. Esto tiene sentido a la luz de cómo quedaron entrenadas las 193 neuronas nuevas: al estar especializadas y bien separadas para su propia región (a diferencia de las neuronas del catálogo global, que nunca vieron suficientes ejemplos locales como para asignarles un puntaje alto), su ventaja sobre cualquier especie ajena termina siendo lo bastante grande como para no perder la competencia por más candidatos que se sumen.

Versión	Global (%)	Macro (%)	Mejoran	Igual	Empeoran
Baseline	63.6	62.6	—	193	—
v1	85.2	85.4	131	41	21
v2	85.7	86.0	137	30	26

Tabla 6: Comparación agregada entre el baseline, el primer reentrenamiento (v1) y el reentrenamiento con regresión logística (v2). “Mejoran/Igual/Empeoran” cuenta especies respecto del baseline.

La Figura 7 muestra el mismo tipo de histograma usado en la Figura 6, esta vez comparando v1 contra v2 directamente. El cambio es más sutil que el salto inicial del baseline a v1, lo cual era esperable, ya que v1 ya había concentrado la enorme mayoría de las especies en el tramo de 90-100 %. Pero va en la dirección correcta: el tramo más alto vuelve a ganar especies, a costa de los tramos bajos e intermedios.




Figura 7: Distribución de accuracy top-1 entre el primer reentrenamiento (v1) y el modelo final (v2).

La cantidad de especies que mejoran respecto del baseline también es la más alta de todos los reentrenamientos probados: 137 de 193, contra 131 del primer intento. Vale la pena ser honestos sobre lo que este resultado no es: no se trata de una mejora estrictamente superior en cada especie individual. De las 193 especies, 48 mejoran respecto de v1, 104 quedan exactamente igual, y 41 empeoran (Tabla 7). v2 sigue sin cumplir el ideal de mejorar en absolutamente

todos los casos sin excepción, pues 26 especies quedan por debajo del baseline original, cinco más que en v1, algo que, con un único clasificador lineal compartido entre 193 especies, resulta difícil de garantizar de forma perfecta: mover la frontera de decisión para ayudar a una especie casi inevitablemente mueve un poco la de las especies vecinas en el espacio de embeddings, para bien o para mal.

Especie	v1 (%)	v2 (%)	Diferencia
<i>Mayores mejoras</i>			
<i>Geothlypis velata</i>	50.0	90.0	+40.0
<i>Agelasticus thilius</i>	50.0	80.0	+30.0
<i>Chloroceryle americana</i>	60.0	90.0	+30.0
<i>Furnarius rufus</i>	70.0	100.0	+30.0
<i>Progne chalybea</i>	60.0	90.0	+30.0
<i>Mayores caídas</i>			
<i>Anser anser</i>	70.0	30.0	-40.0
<i>Sturnus vulgaris</i>	90.0	50.0	-40.0
<i>Leistes loyca</i>	80.0	50.0	-30.0
<i>Podilymbus podiceps</i>	100.0	70.0	-30.0
<i>Serpophaga nigricans</i>	100.0	77.8	-22.2

Tabla 7: Especies con mayor cambio, en ambos sentidos, entre v1 y v2.

Aun así, en el balance agregado v2 es el mejor modelo obtenido a lo largo de todo este proceso, y además descansa en una base metodológica más sólida que el primer intento: usa la misma herramienta de optimización convexa ya validada en el diagnóstico de la Parte I, y maneja tanto el desbalance de clases como la falta de negativos duros de forma estándar y consistente para las 193 especies por igual. A esto se suma que, al haberse exportado en modo Append, el dispositivo conserva la capacidad de reconocer cualquiera de las 6522 especies del catálogo original de BirdNET, algo que un archivo en modo Replace hubiera descartado por completo, y sin ningún costo medible sobre las 193 especies locales. Por estas razones, v2 es el modelo elegido para instalarse en la Raspberry Pi del LSD-Tector.